Основы глубинного обучения

Лекция 3

Свёрточные сети

Евгений Соколов

esokolov@hse.ru

НИУ ВШЭ, 2023

Свёртка

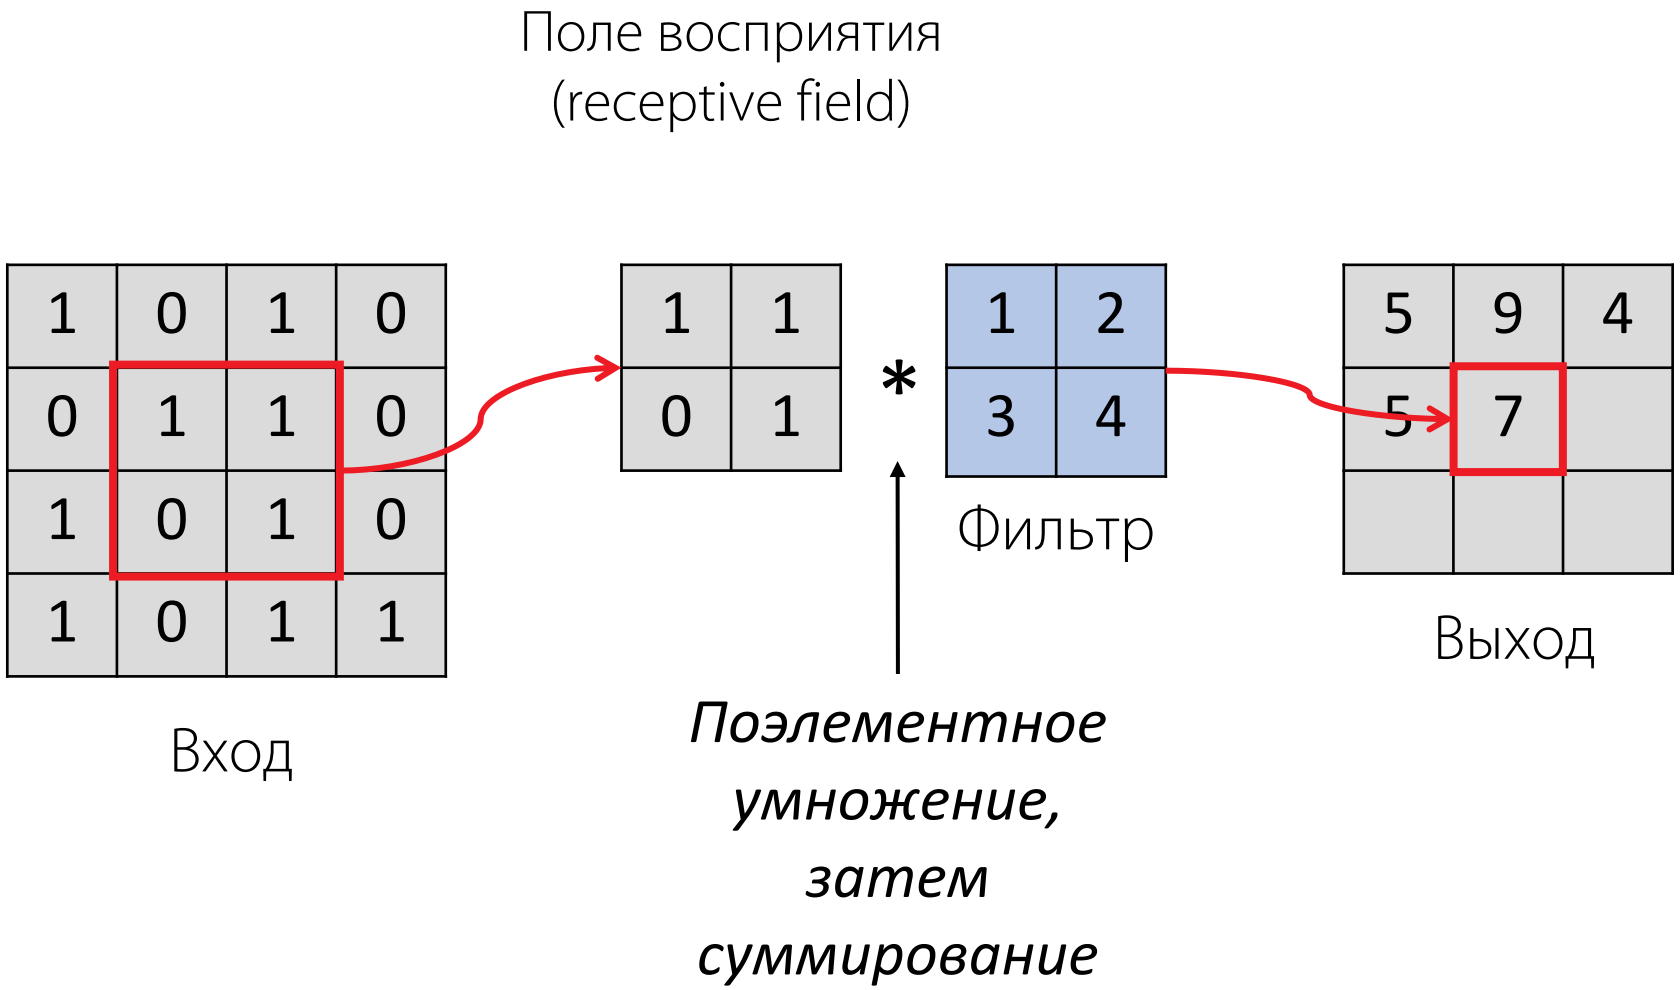
Поле восприятия
(receptive field)
1 0 1 0
0 1 1 0
1 0 1 0
1 0 1 1
Вход
1 1
0 1
*
1 2
3 4
Фильтр
Поэлементное умножение, затем суммирование
5 9 4
5 7
Выход

Свёртка инвариантна к сдвигам

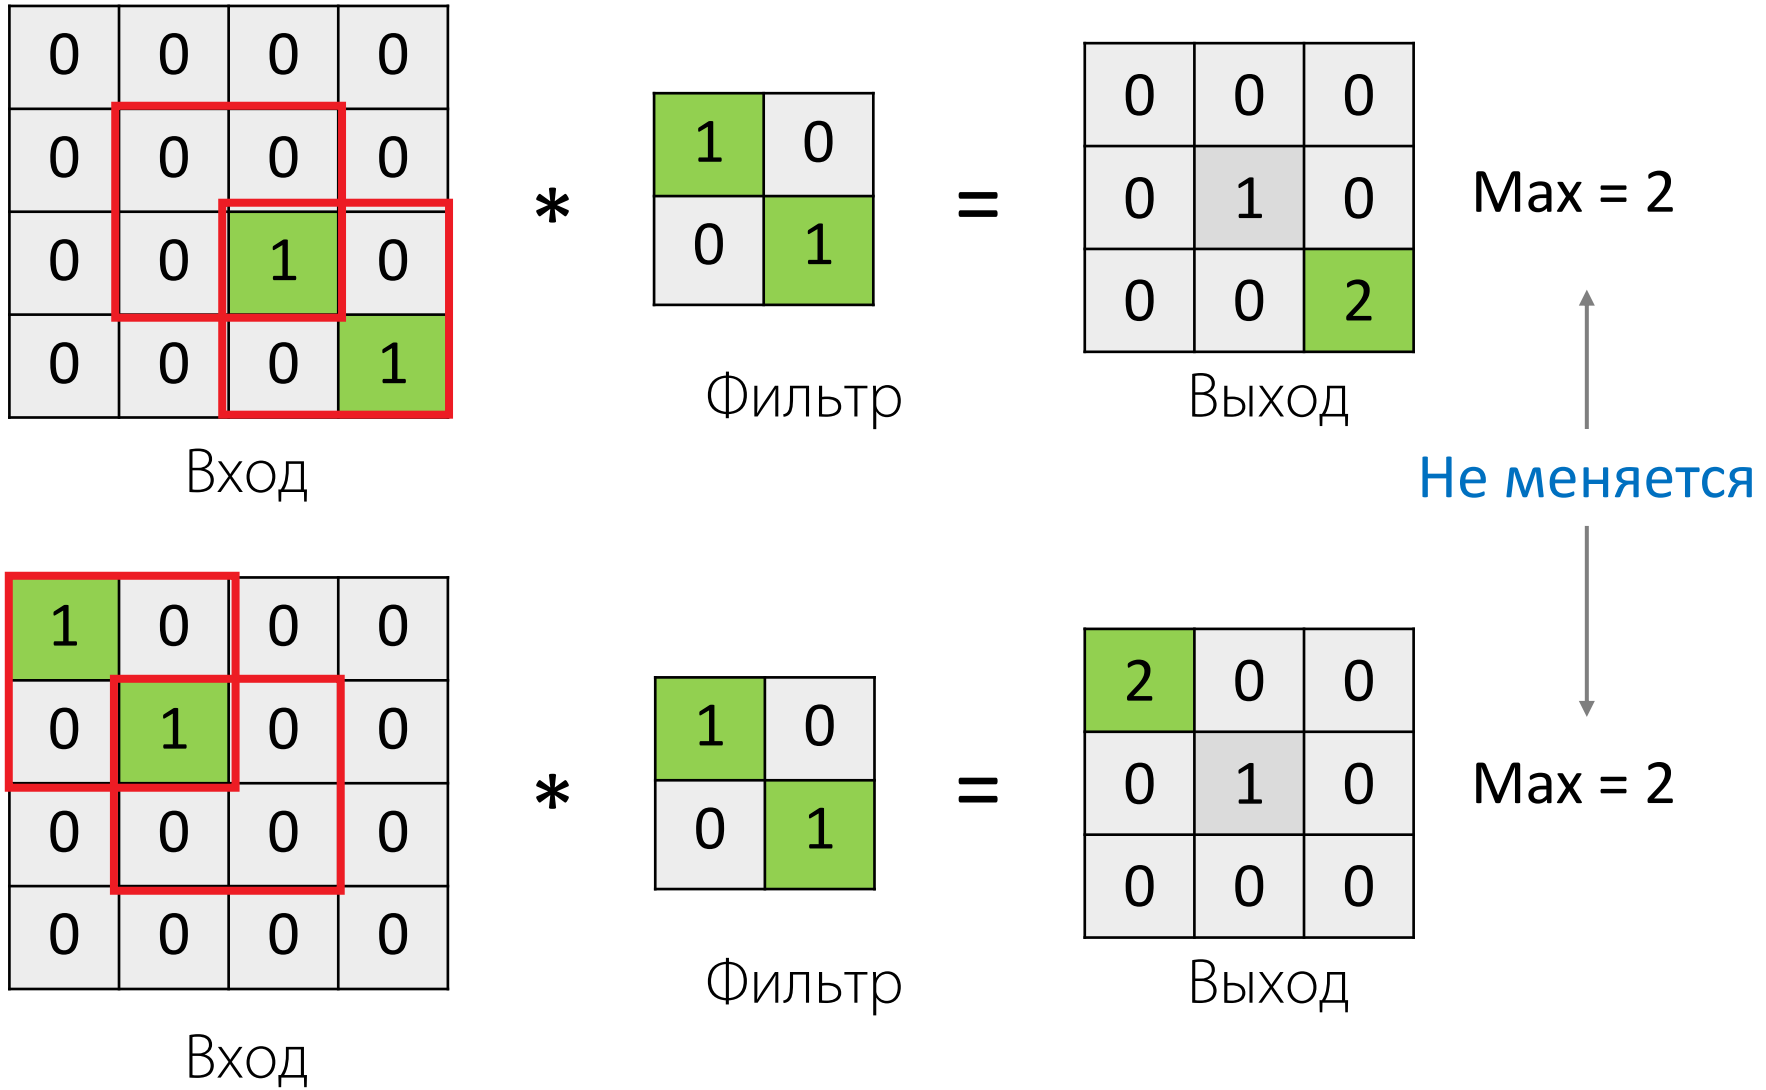

Свёртки в компьютерном зрении

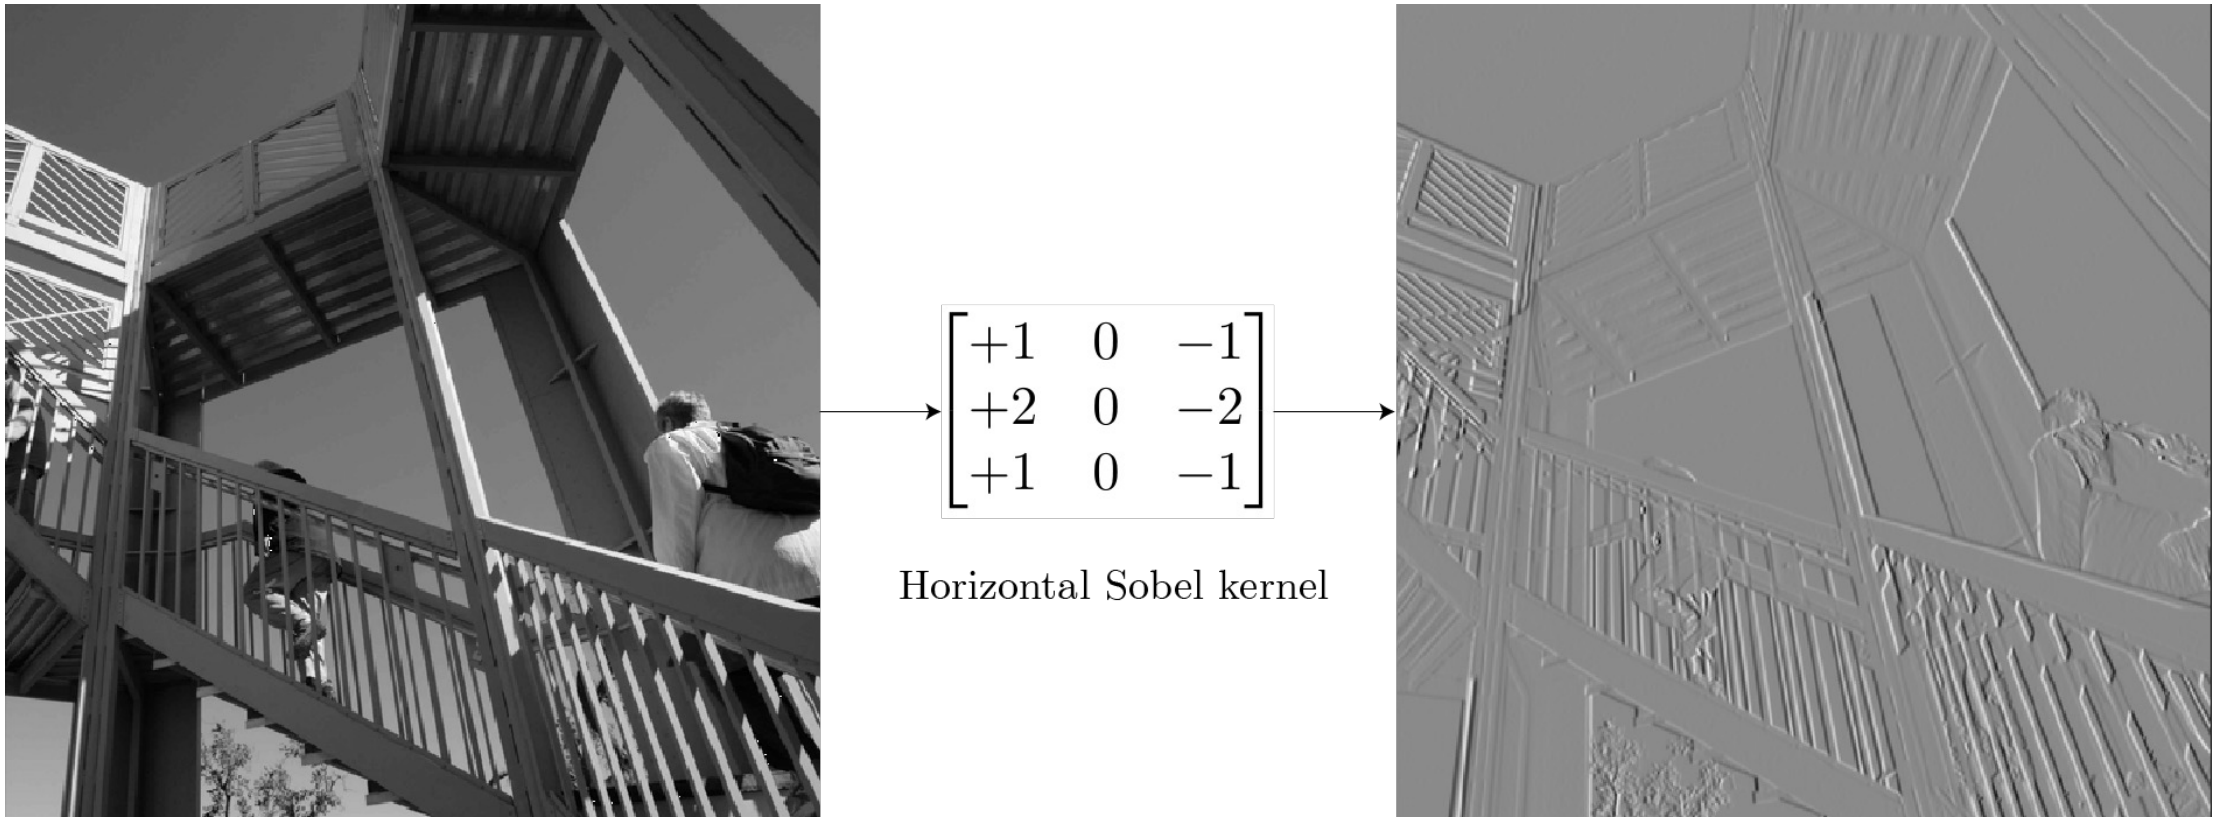

$$\begin{bmatrix} +1 & 0 & -1 \\ +2 & 0 & -2 \\ +1 & 0 & -1 \end{bmatrix}$$

Horizontal Sobel kernel

https://towardsdatascience.com/intuitively-understanding-convolutions-for-deep-learning-1f6f42faee1

Свёртка

$$\mathrm{Im}^{out}(x,y) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \left(K(i,j)\, \mathrm{Im}^{in}(x+i, y+j) + b \right)$$

Свёртка

$$\mathrm{Im}^{out}(x,y) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \left(K(i,j)\, \mathrm{Im}^{in}(x+i, y+j) + b \right)$$

- Пиксель в результирующем изображении зависит только от небольшого участка исходного изображения (local connectivity)
- Веса одни и те же для всех пикселей результирующего изображения (shared weights)

Свёртка

- Обычно исходное изображение цветное!
- Это означает, что в нём несколько каналов (R, G, B)
- Учтём в формуле:

$$\mathrm{Im}^{out}(x,y) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \sum_{c=1}^{C} \left(K(i,j,c)\, \mathrm{Im}^{in}(x+i, y+j, c) + b \right)$$

Свёртка

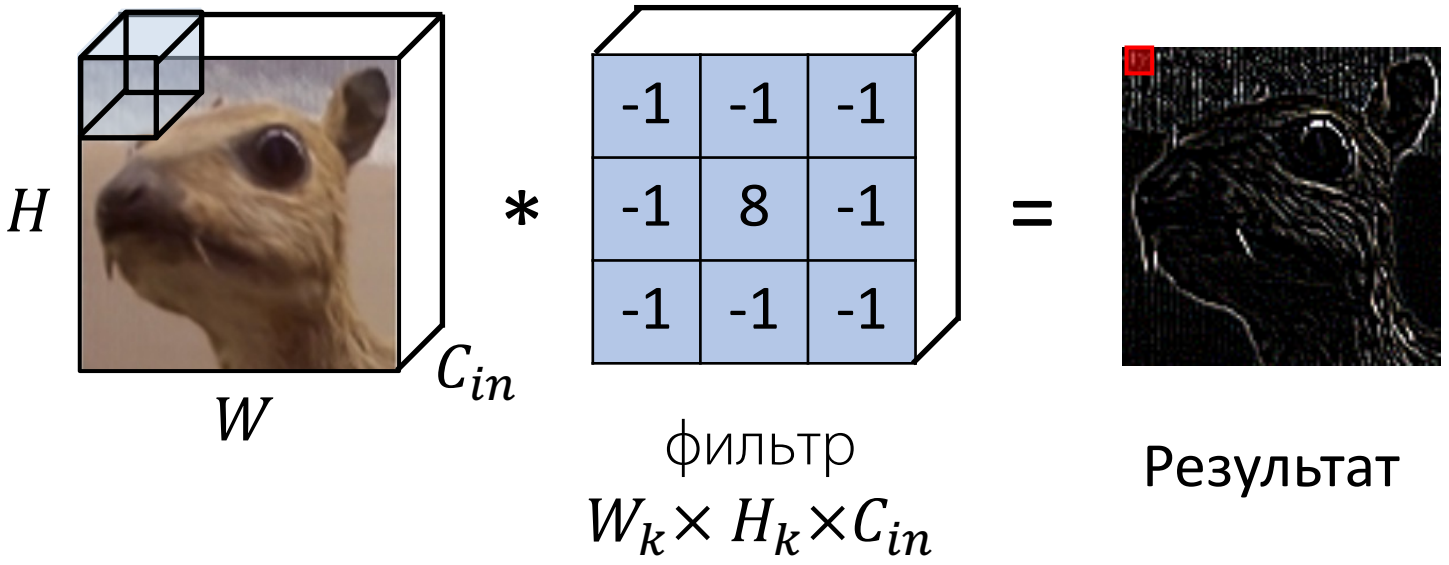

Свёртка

- Одна свёртка выделяет конкретный паттерн на изображении
- Нам интересно искать много паттернов
- Сделаем результат трёхмерным:

$$\mathrm{Im}^{out}(x, y, t) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \sum_{c=1}^{C} \left(K_t(i, j, c)\, \mathrm{Im}^{in}(x + i, y + j, c) + b_t \right)$$

Число параметров

$$\mathrm{Im}^{out}(x, y, t) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \sum_{c=1}^{C} \left(K_t(i, j, c)\, \mathrm{Im}^{in}(x + i, y + j, c) + b_t \right)$$

- Обучается только фильтр
- $\left((2d + 1)^2 * C + 1\right) * T$ параметров

- Как из этого сделать модель — обсудим позже

Receptive field

Receptive field

- Возьмём пиксель в итоговом изображении (после свёрточных слоёв)
- От какой части входного изображения зависит значение в этом пикселе?

Receptive field

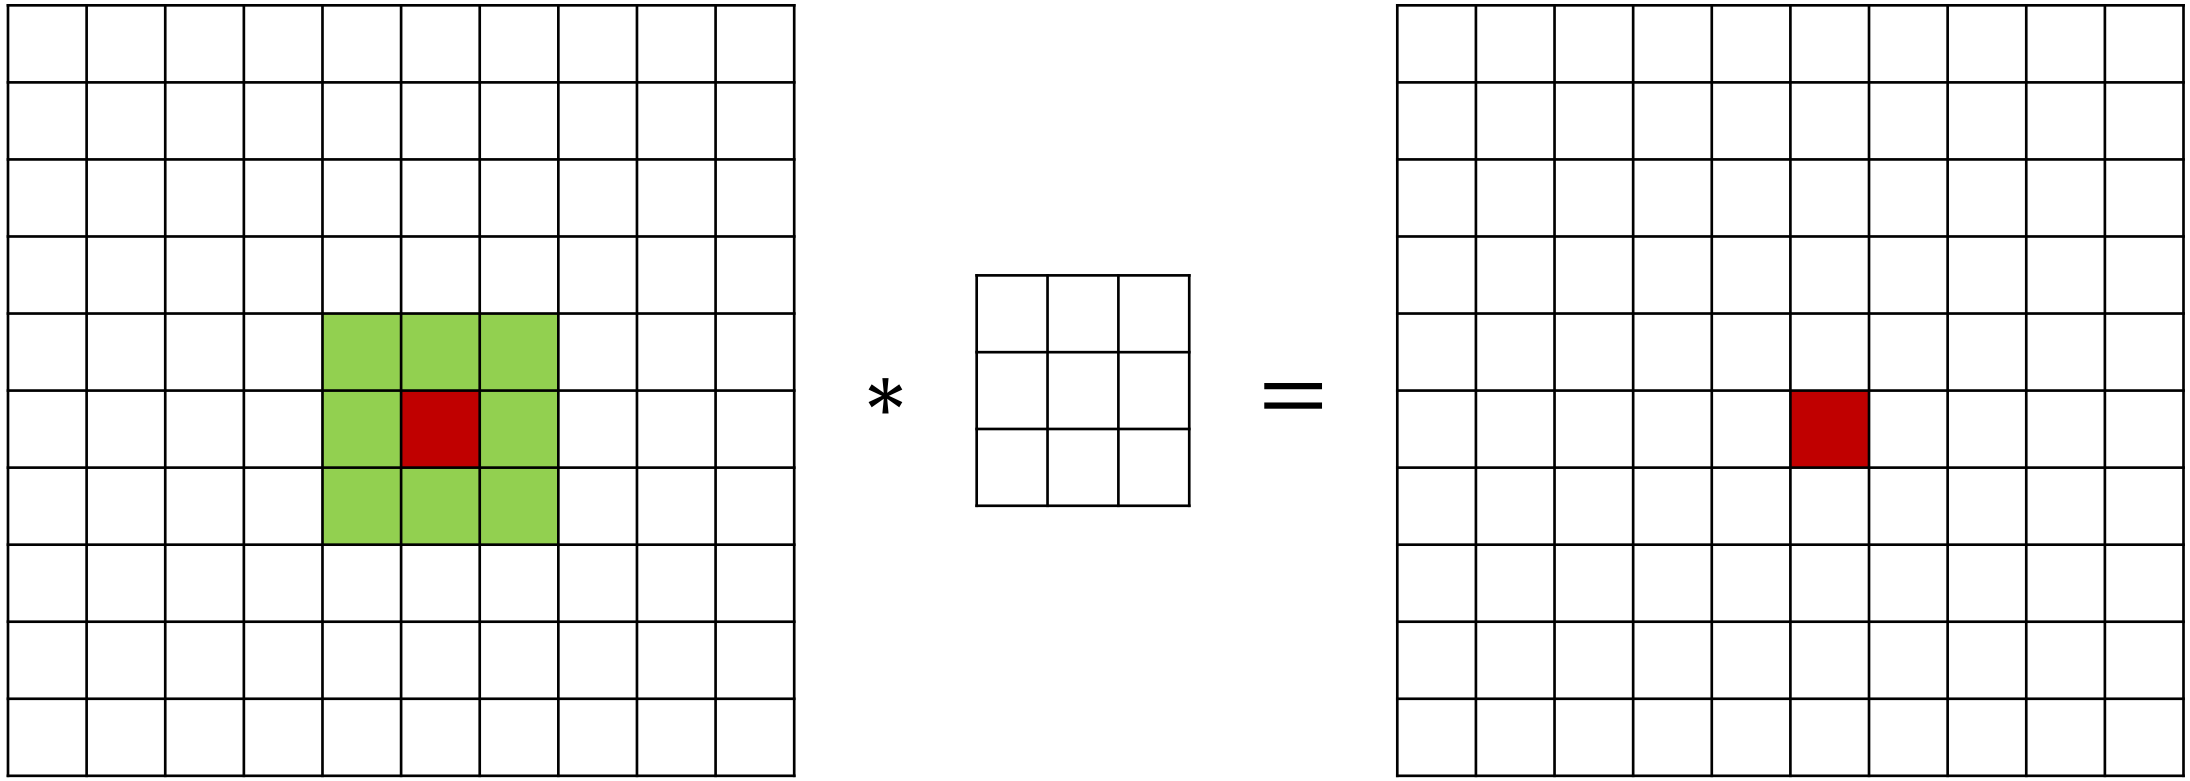

Поле восприятия: 3 x 3

Receptive field

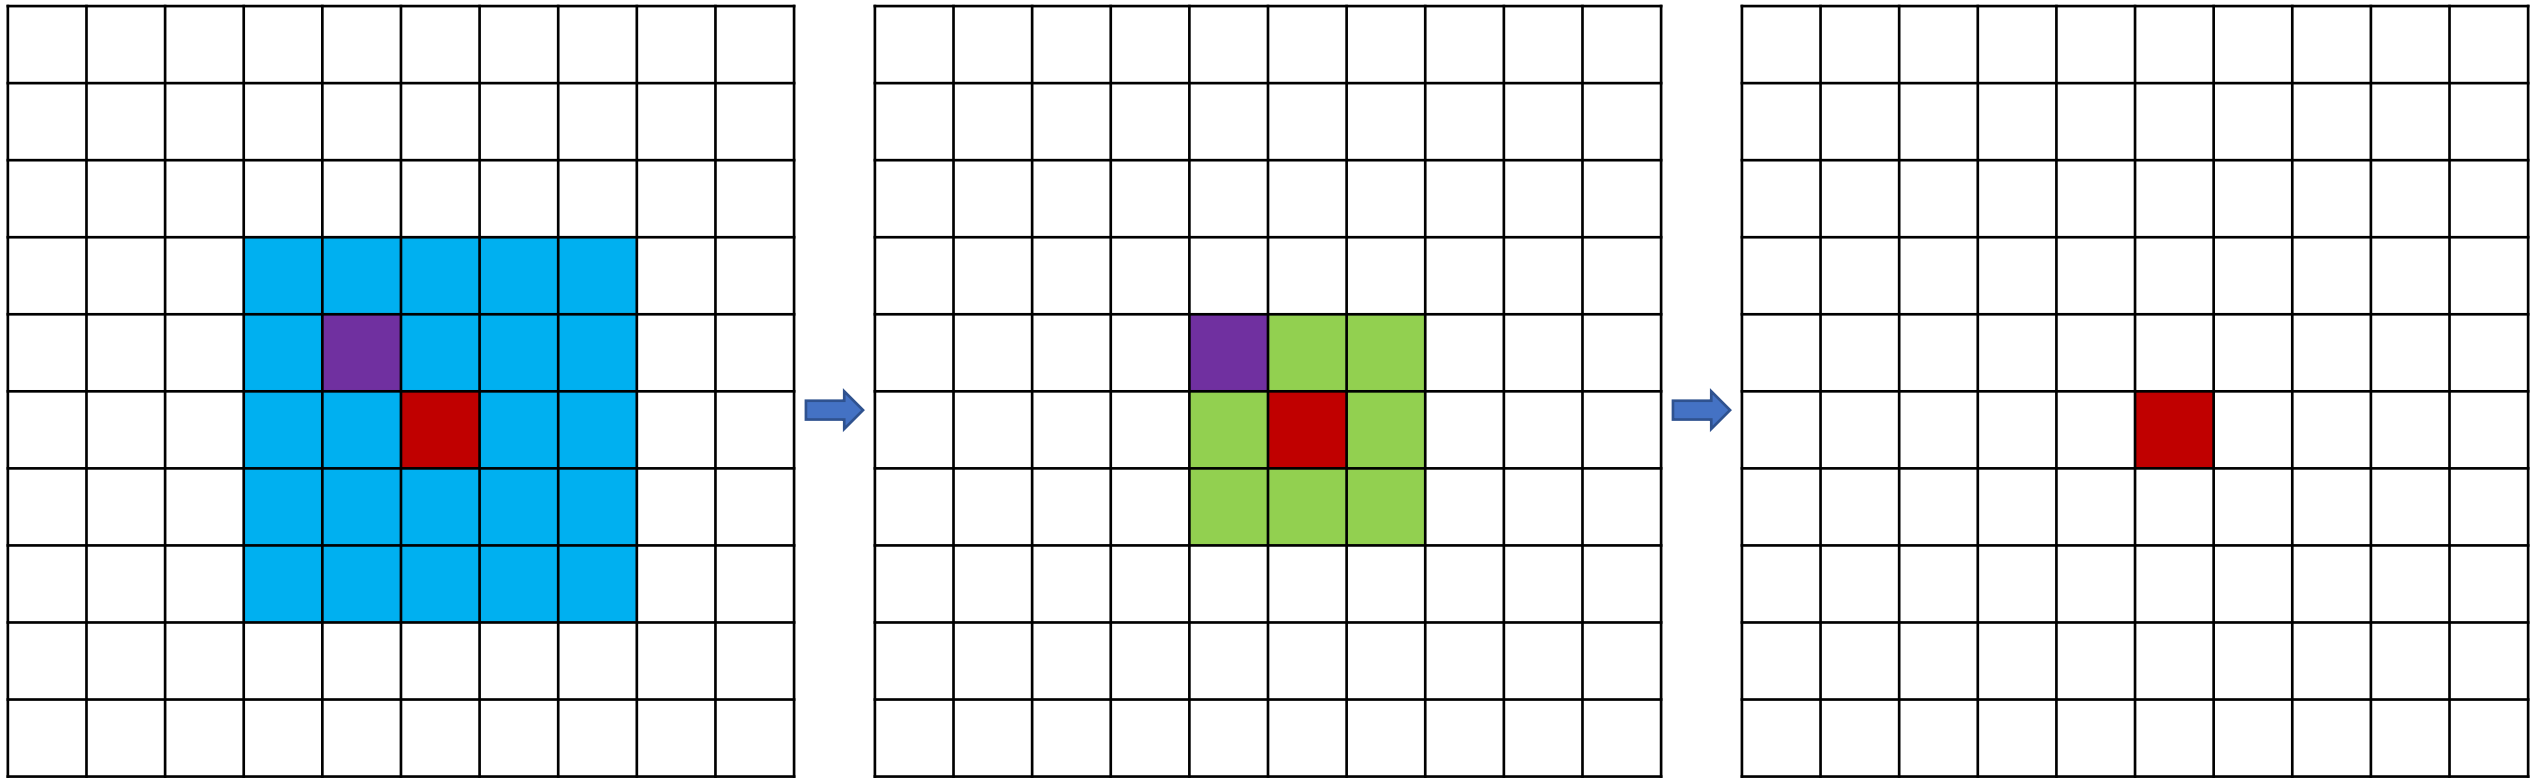

Поле восприятия: 5 x 5

Receptive field

Поле восприятия для свёртки 3 x 3:

- После 1 свёрточного слоя: 3 x 3
- После 2 свёрточных слоев: 5 x 5
- После 3 свёрточных слоёв: 7 x 7

Receptive field

Поле восприятия для свёртки 5 x 5:

Receptive field

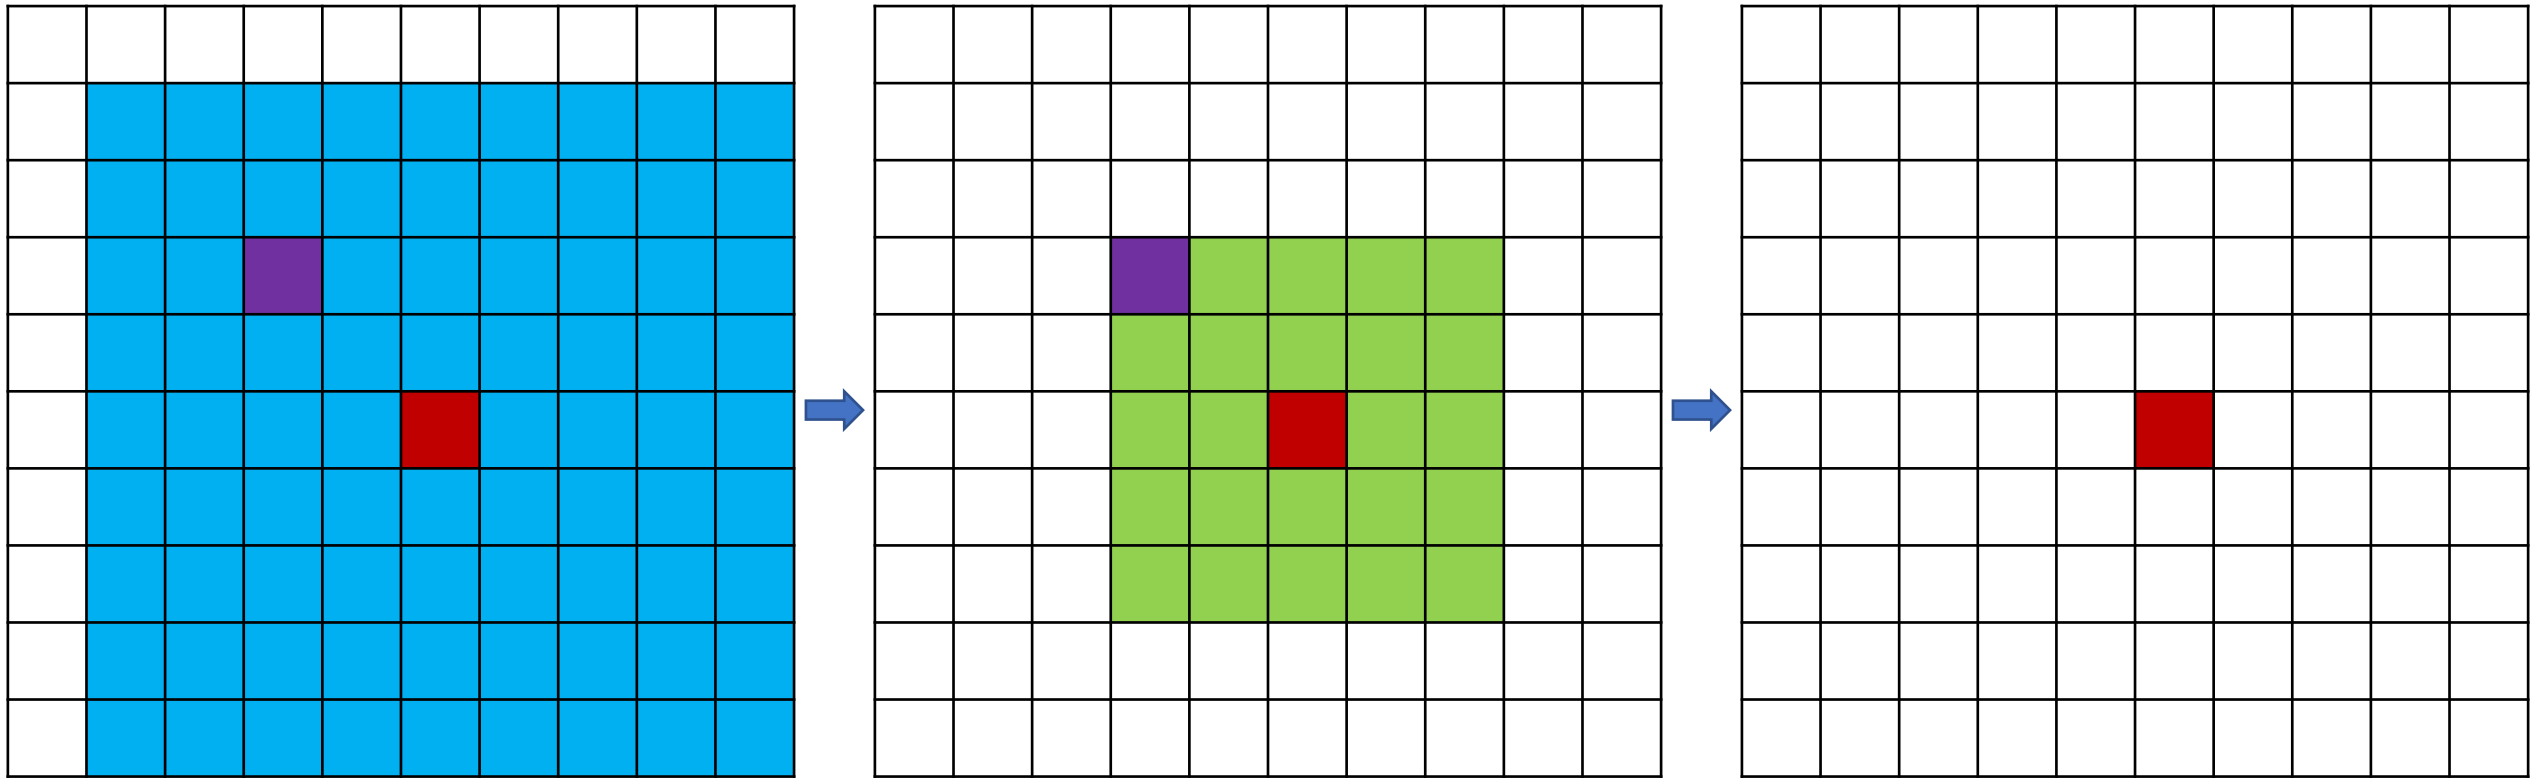

Поле восприятия: 5 x 5

Receptive field

Поле восприятия для свёртки 5 x 5:

- После 1 свёрточного слоя: 5 x 5
- После 2 свёрточных слоев: 9 x 9
- После 3 свёрточных слоёв: 13 x 13

Нужно очень много слоёв, если изображение размера 512 x 512

Свёртки с пропусками (strides)

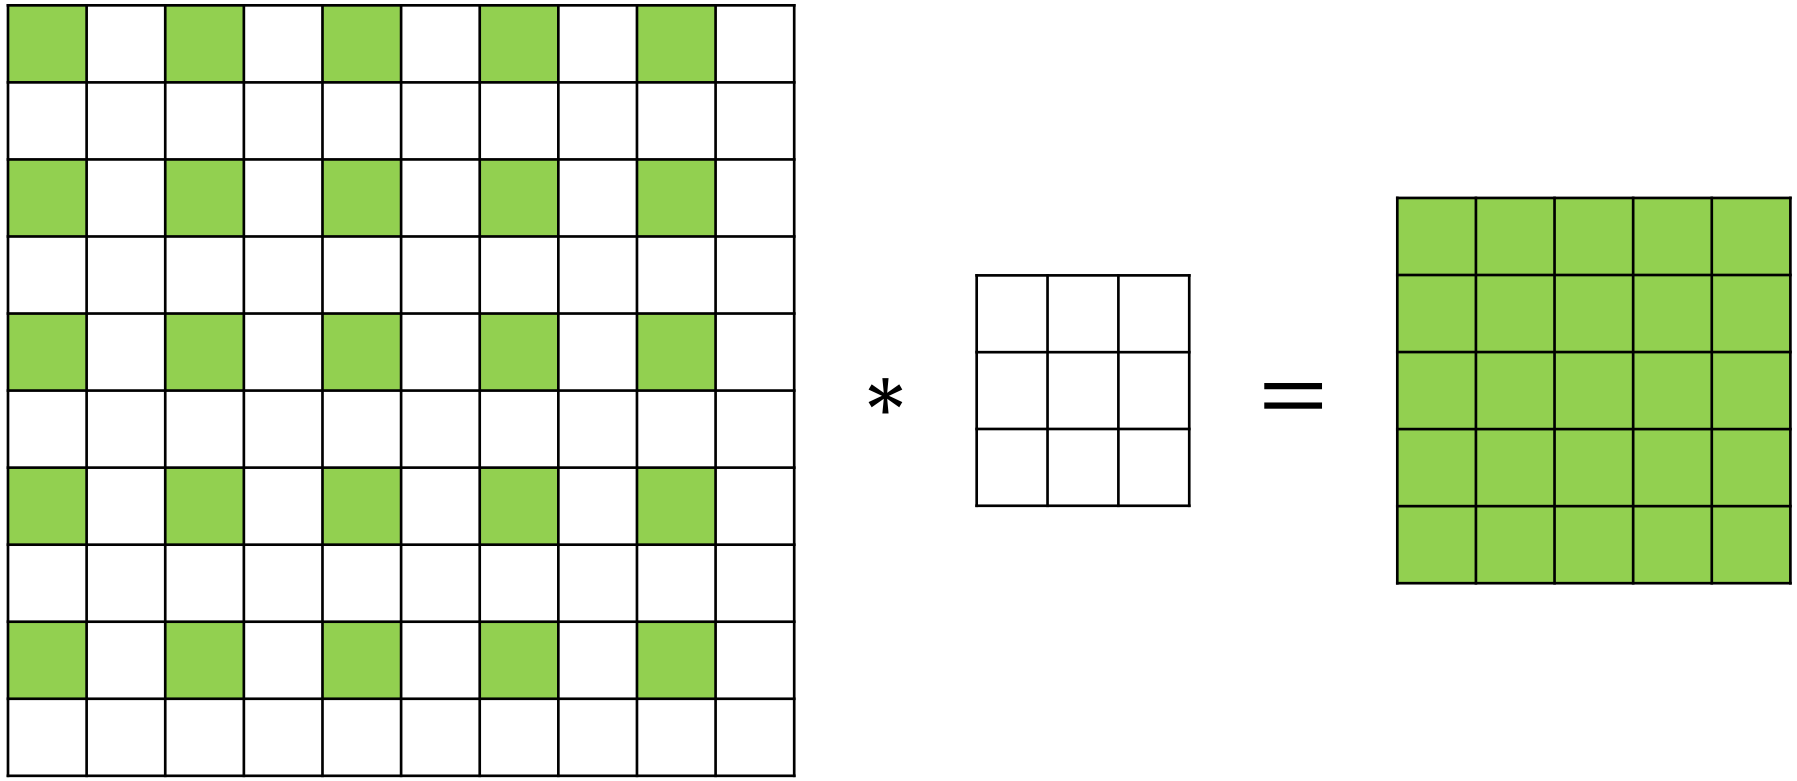

$$s = 2$$

Свёртки с пропусками (strides)

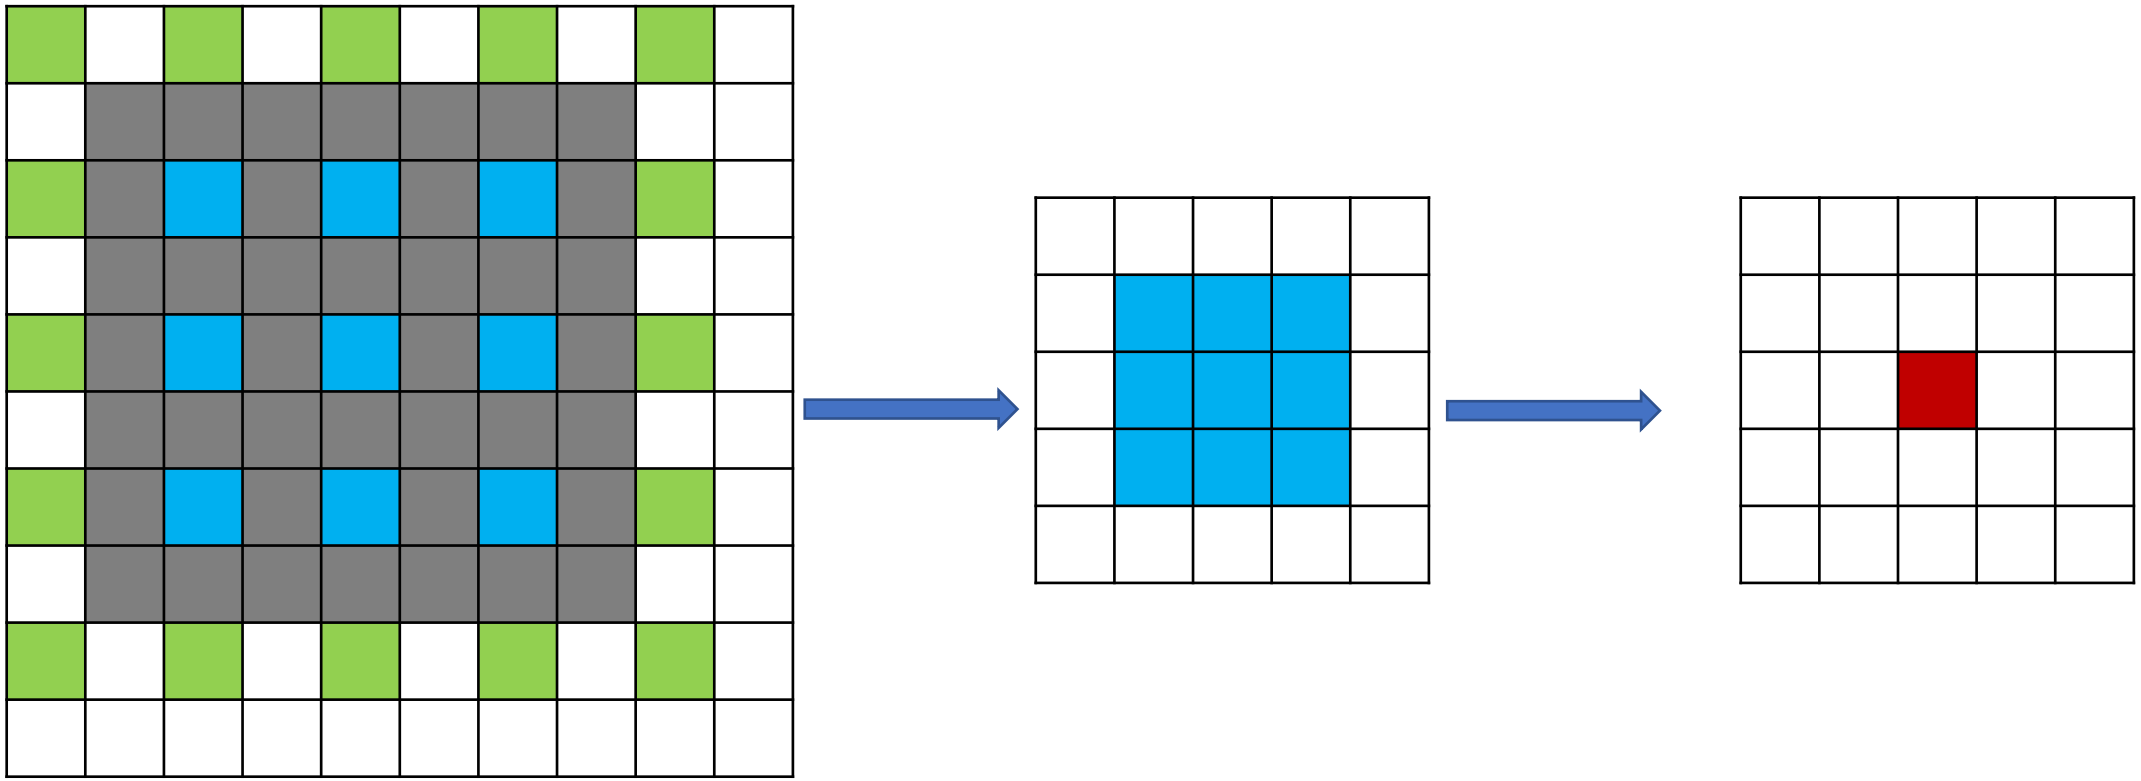

Поле восприятия: 7 x 7

Свёртки с пропусками (strides)

Подробности про подсчёт размера поля:
https://distill.pub/2019/computing-receptive-fields/

Dilated convolutions («раздутые» свёртки)

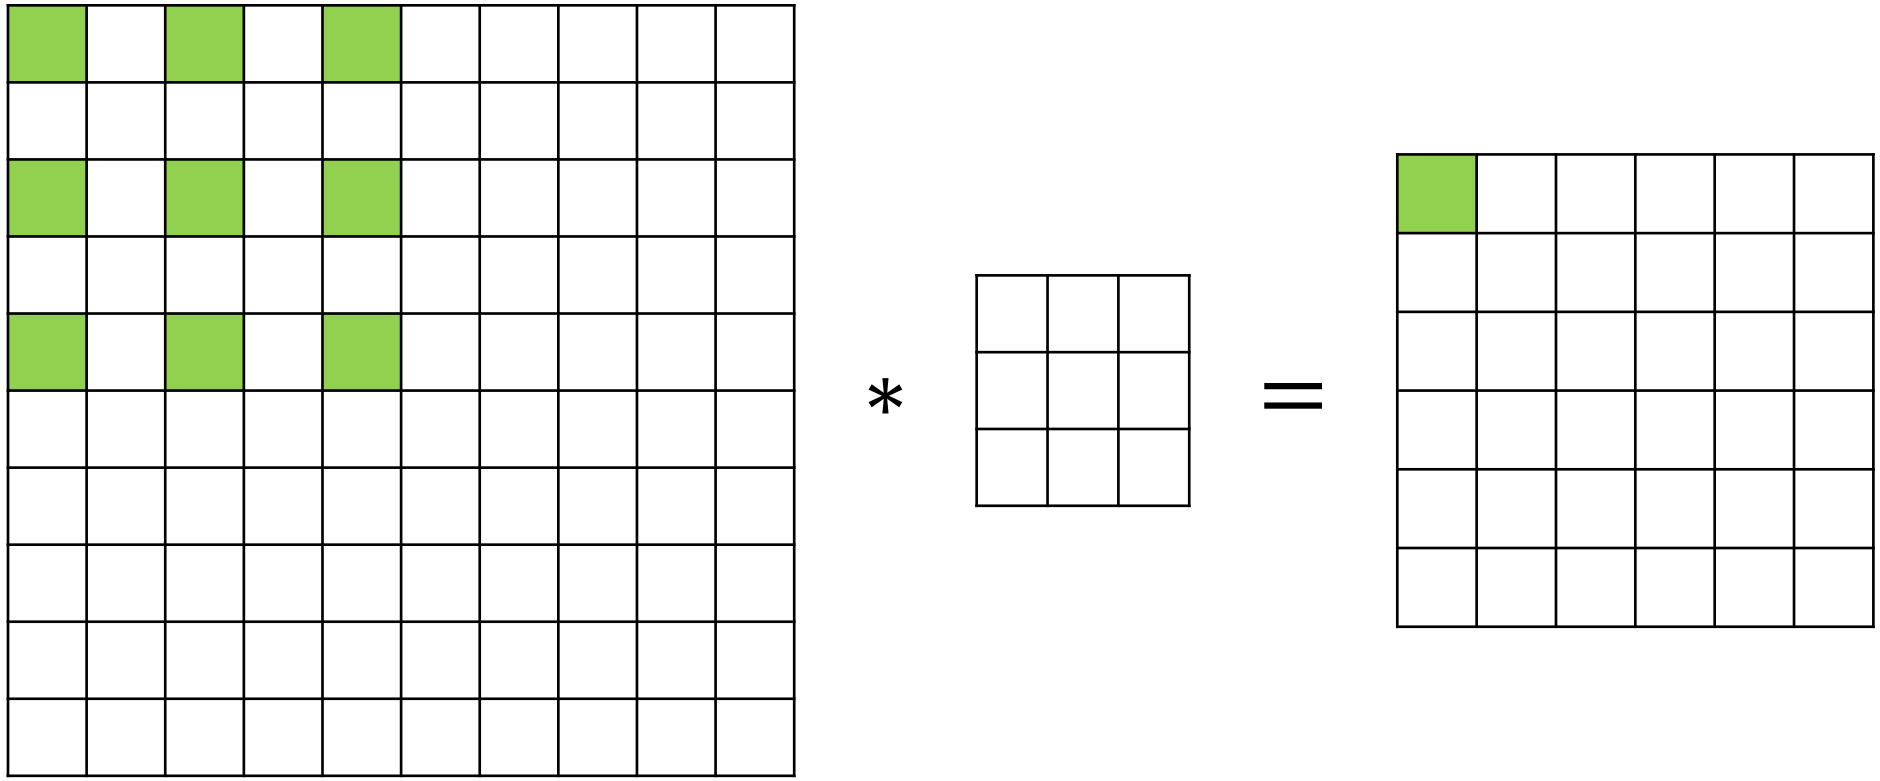

$l = 2$

Dilated convolutions («раздутые» свёртки)

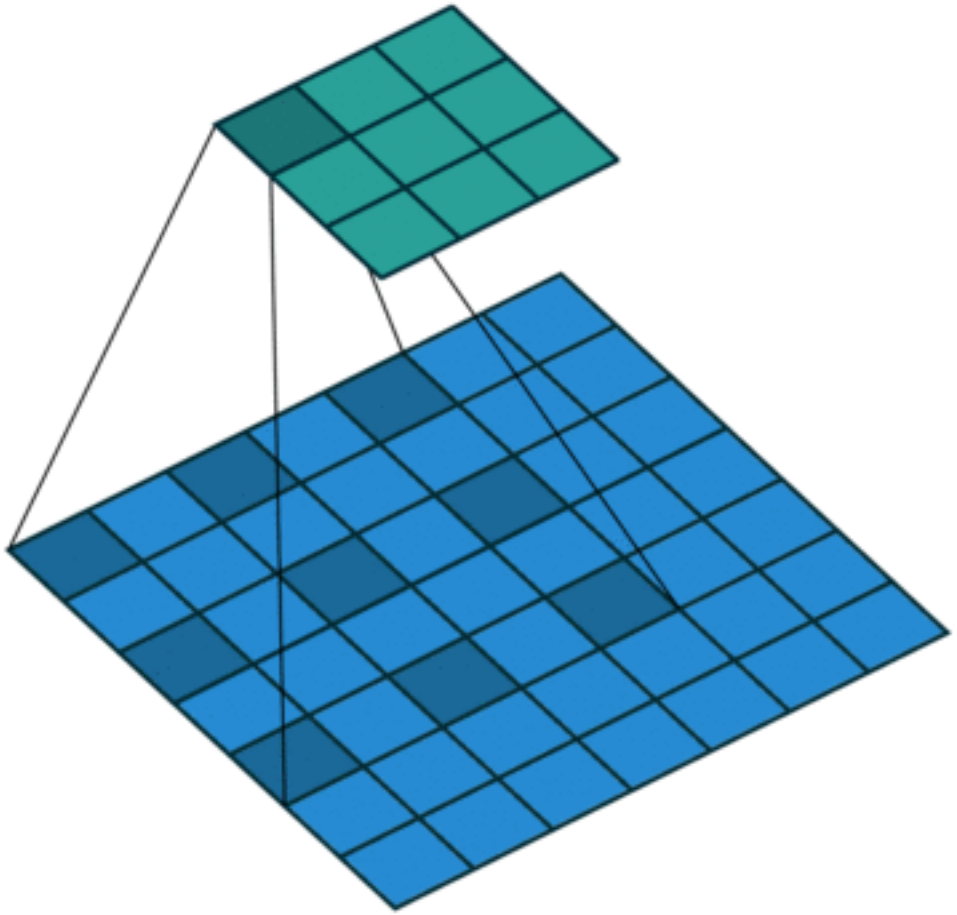

https://towardsdatascience.com/review-dilated-convolution-semantic-segmentation-9d5a5bd768f5

Dilated convolutions («раздутые» свёртки)

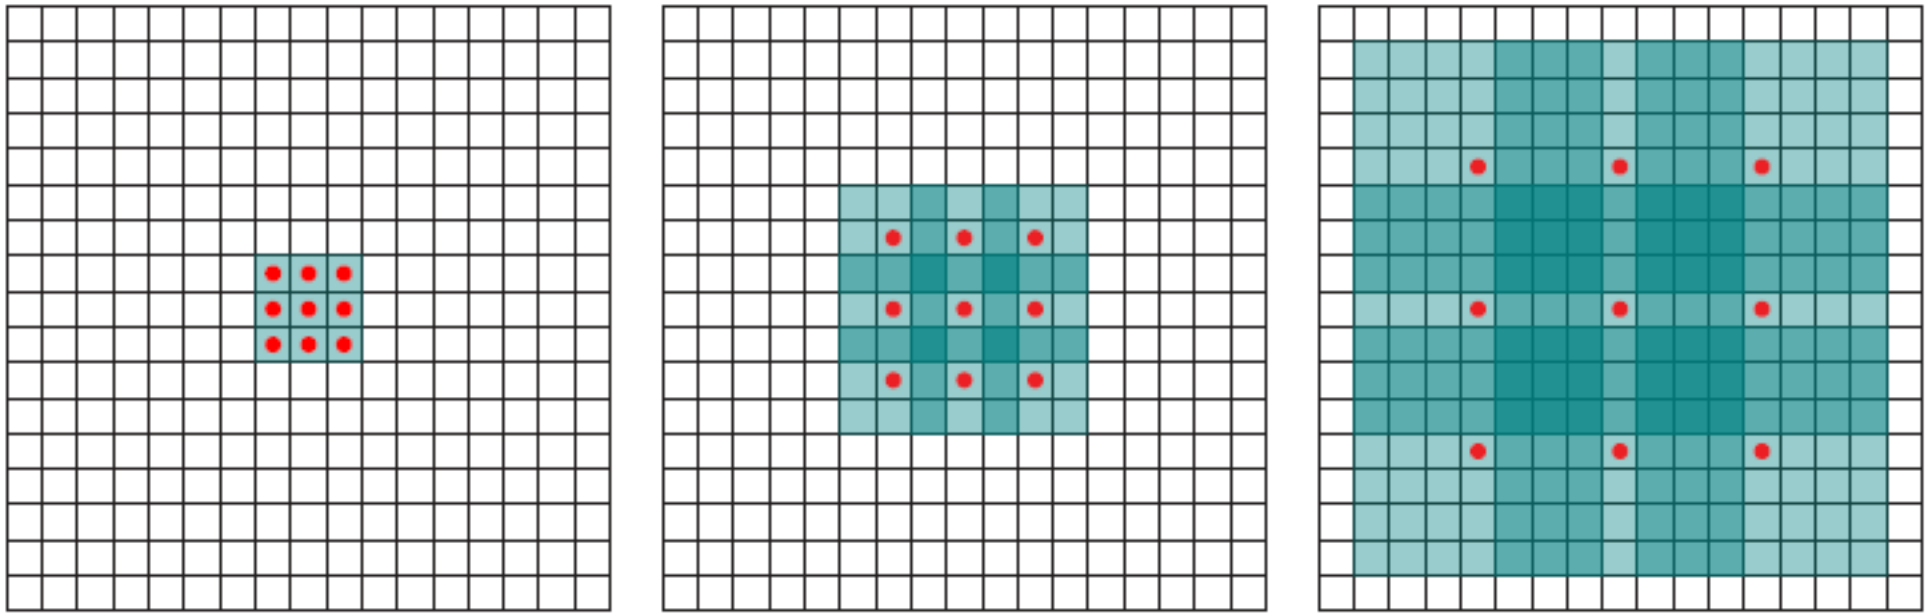

$l = 1$ $l = 2$ $l = 4$

https://towardsdatascience.com/review-dilated-convolution-semantic-segmentation-9d5a5bd768f5

Pooling

1	0	2	1	0	0
0	1	3	2	1	2

1	3	2

Max-pooling с фильтром 2x2

Pooling

- Разбивает изображение на участки $n \times m$ и считает некоторую статистику в каждом участке (обычно максимум)
- Существенно сокращает размер изображения (значит, увеличивает поле восприятия следующих слоёв)
- Не имеет параметров

Зачем это всё?

- Важно следить за тем, чтобы последние свёрточные слои имели размер поля восприятия, сравнимый со всей картинкой

Padding

Свёртки

- Если применять свёртку по формуле, то выходное изображение будет меньше входного

Свёртки

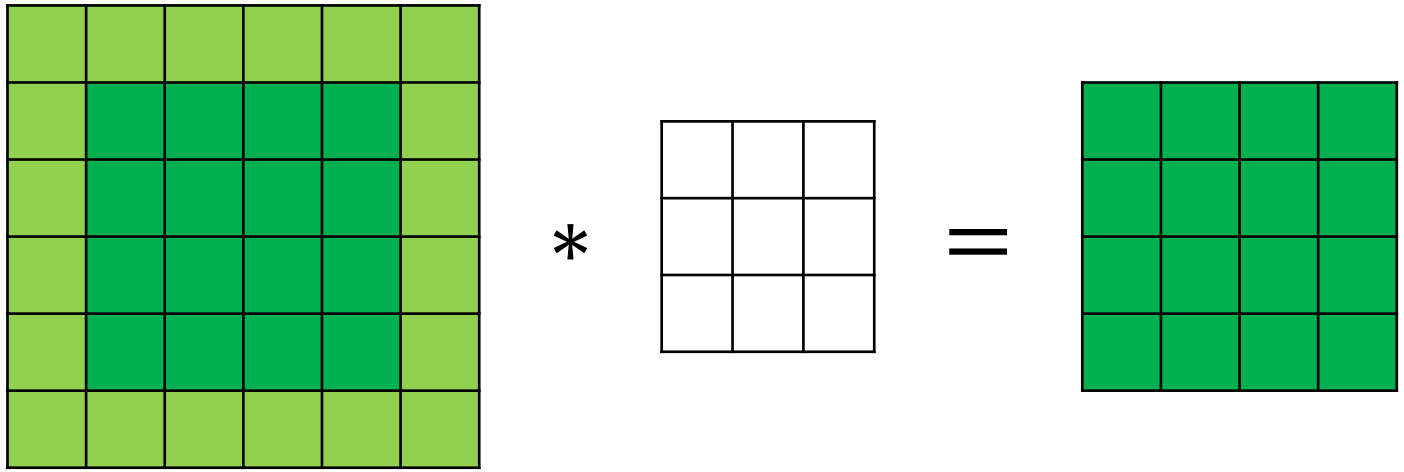

Valid mode

- При честном подсчёте свёрток пиксели на краях не оказывают большого влияния на результат

Не увидим, что фильтр имеет хороший отклик при помещении центра в этот пиксель

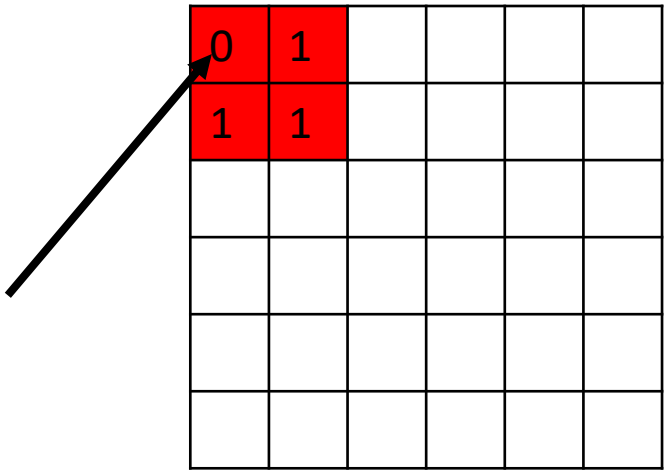

*

0	0	1
0	0	1
1	1	1

Zero padding

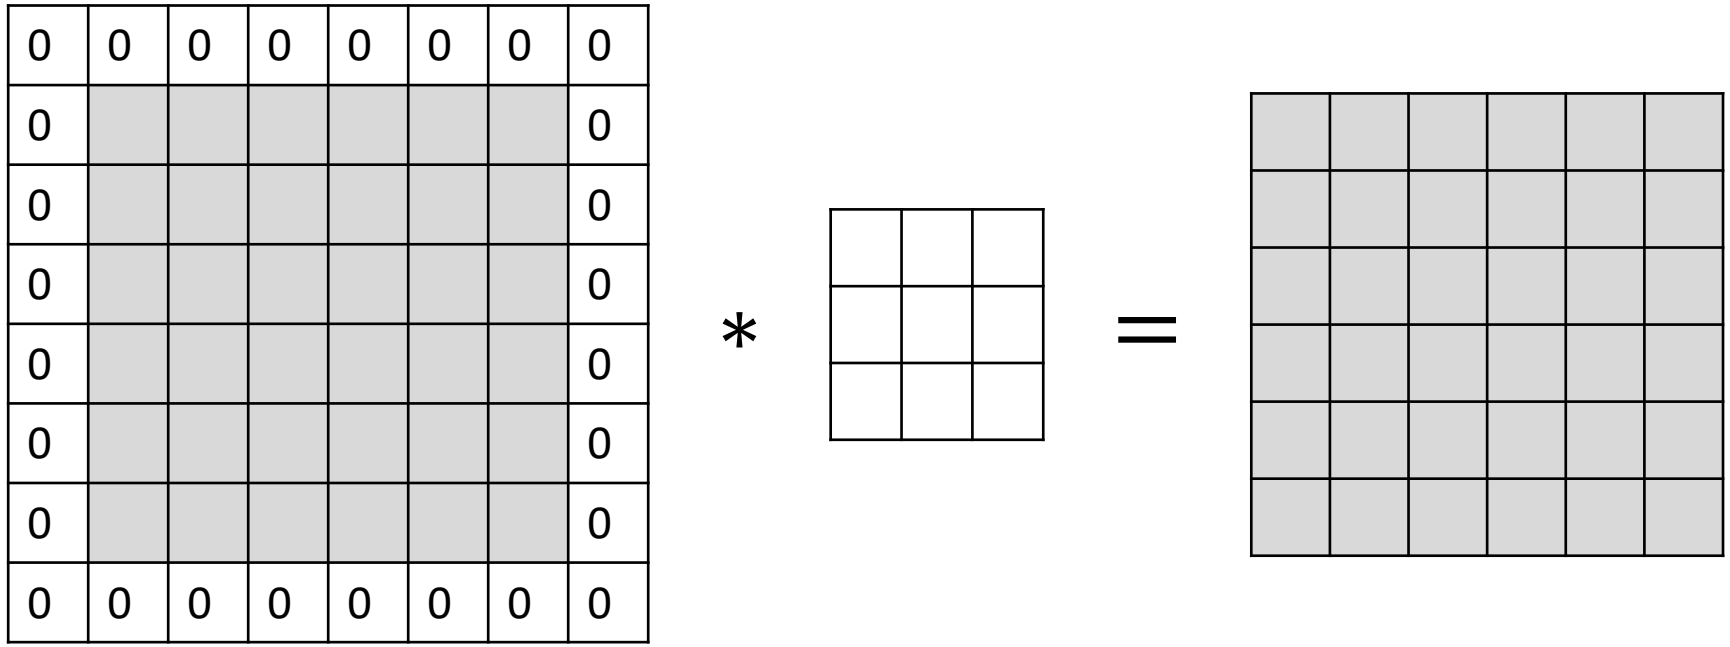

Zero padding

- Добавляем по границам нули так, чтобы посчитанная после этого свёртка в valid mode давала изображение такого же размера, как исходное
- Есть риск, что модель научится понимать, где на изображении края — можем потерять инвариантность

Reflection padding

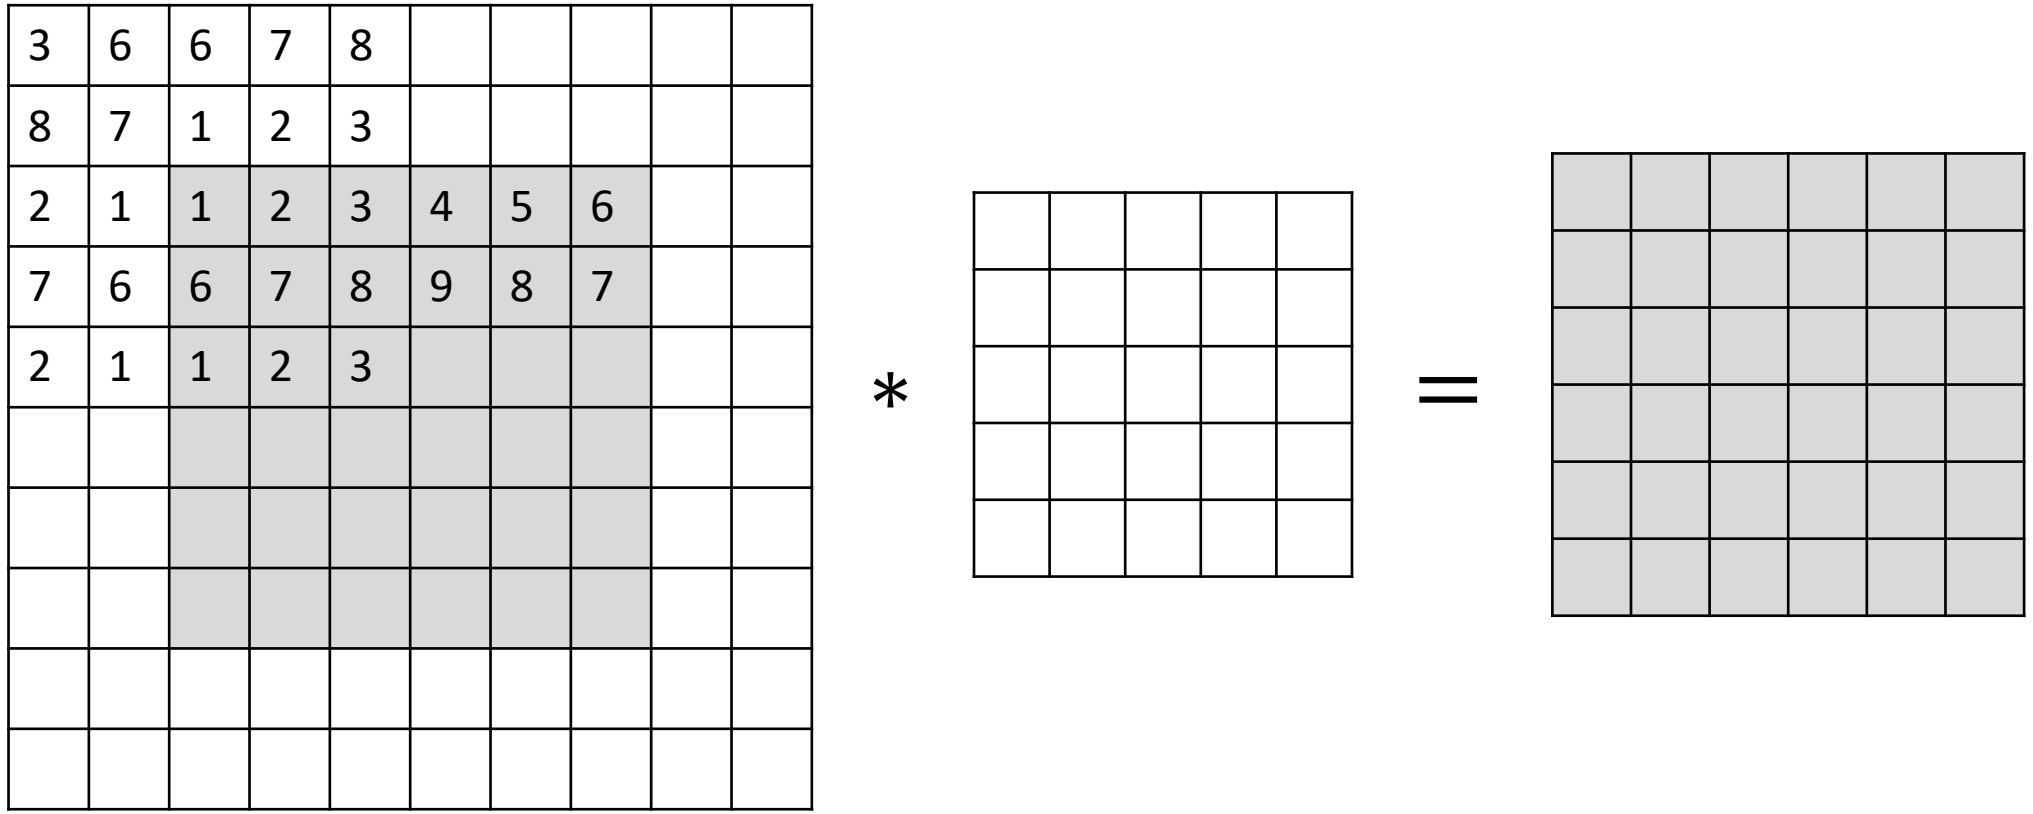

Reflection padding

- Не получится легко находить края изображения
- Но теперь модель может начать находить зеркальные отражения и подбирать фильтры под них

Replication padding

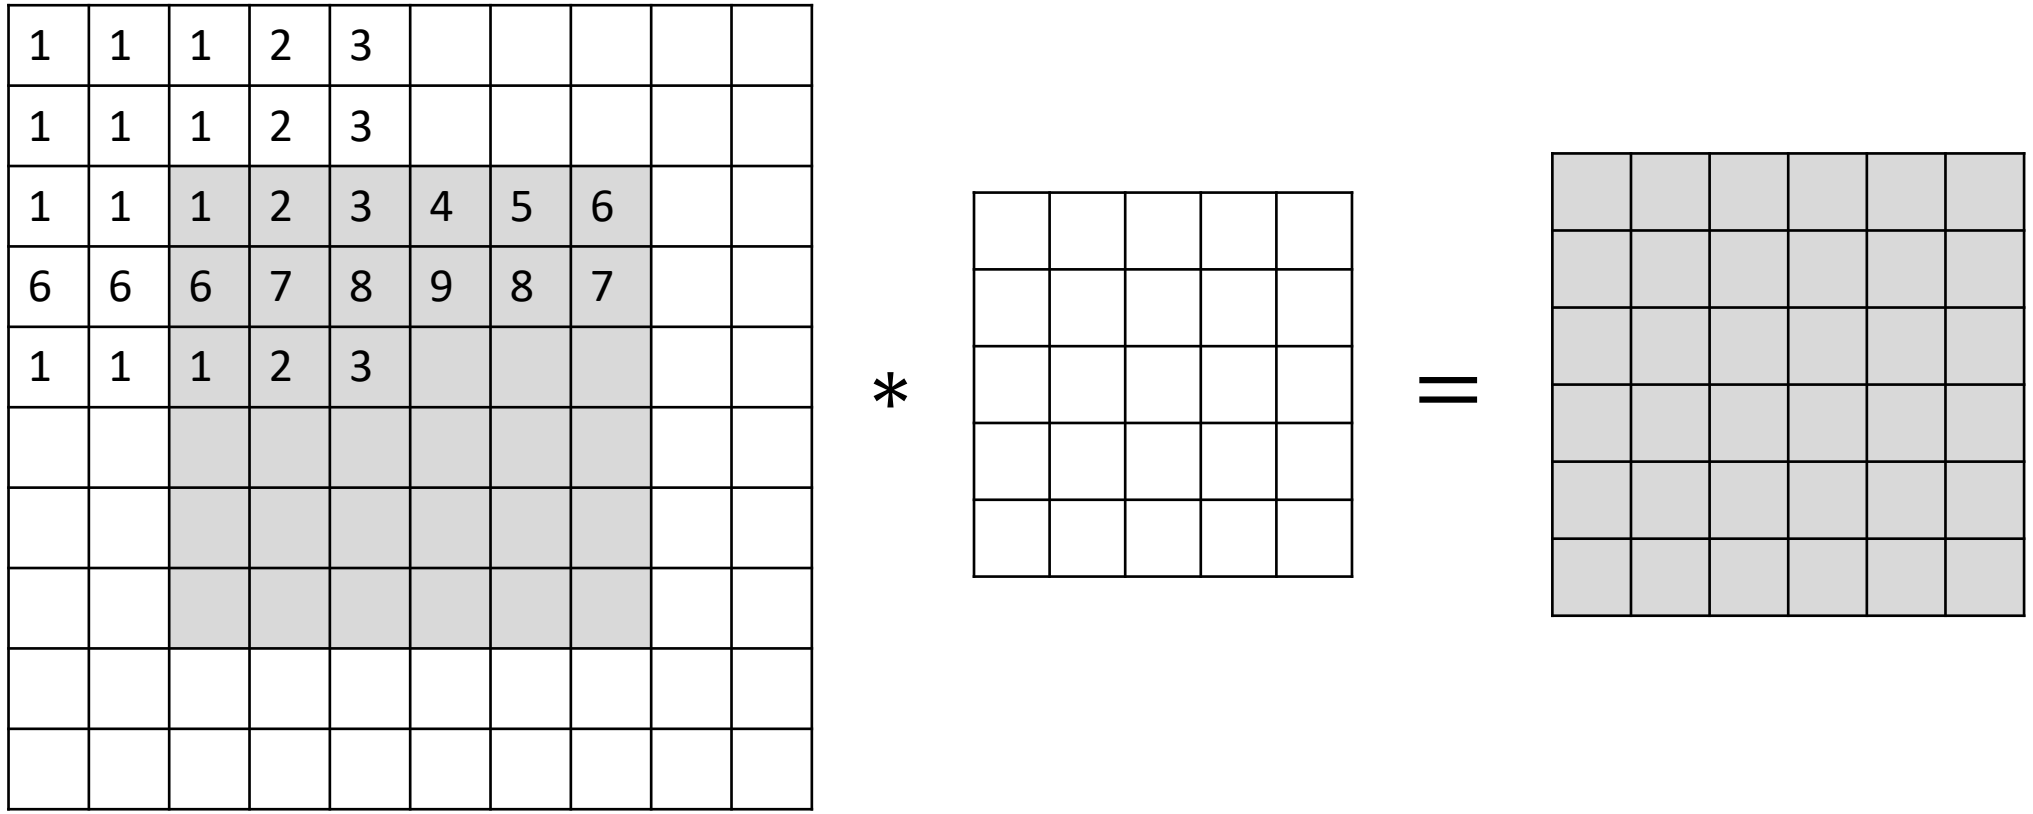

Replication padding

- Пиксель на границе равен ближайшему пикселю из изображения
- Модель всё ещё может настроиться под паттерны, которые возникают из-за такого паддинга

Резюме

- Паддинг позволяет контролировать размер выходных изображений
- Паддинг позволяет учитывать даже объекты на краях
- Разные типа паддингов допускают разные способы переобучения под края

Структура свёрточных сетей

Свёрточный слой

$$\mathrm{Im}^{out}(x, y, t) = \sum_{i=-d}^{d} \sum_{j=-d}^{d} \sum_{c=1}^{C} \left(K_t(i, j, c)\, \mathrm{Im}^{in}(x + i, y + j, c) + b_t \right)$$

Типичная архитектура

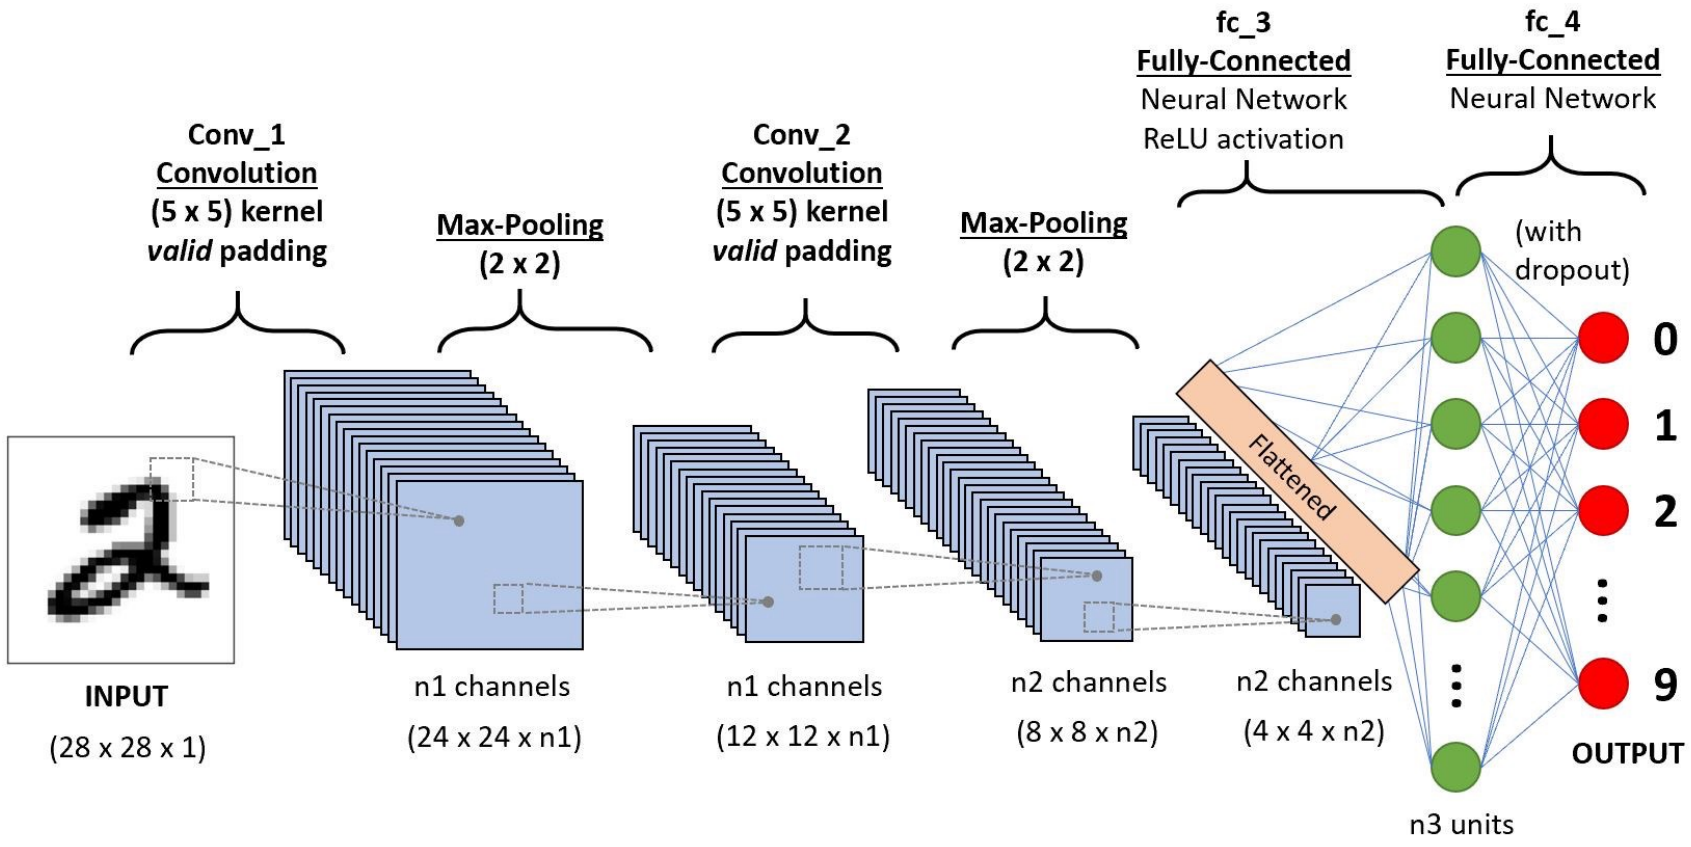

https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53

Типичная архитектура

- Последовательное применение комбинаций вида «свёрточный слой -> нелинейность -> pooling» или «свёрточный слой -> нелинейность»
- Выпрямление (flattening) выхода очередного слоя
- Серия полносвязных слоёв

LeNet

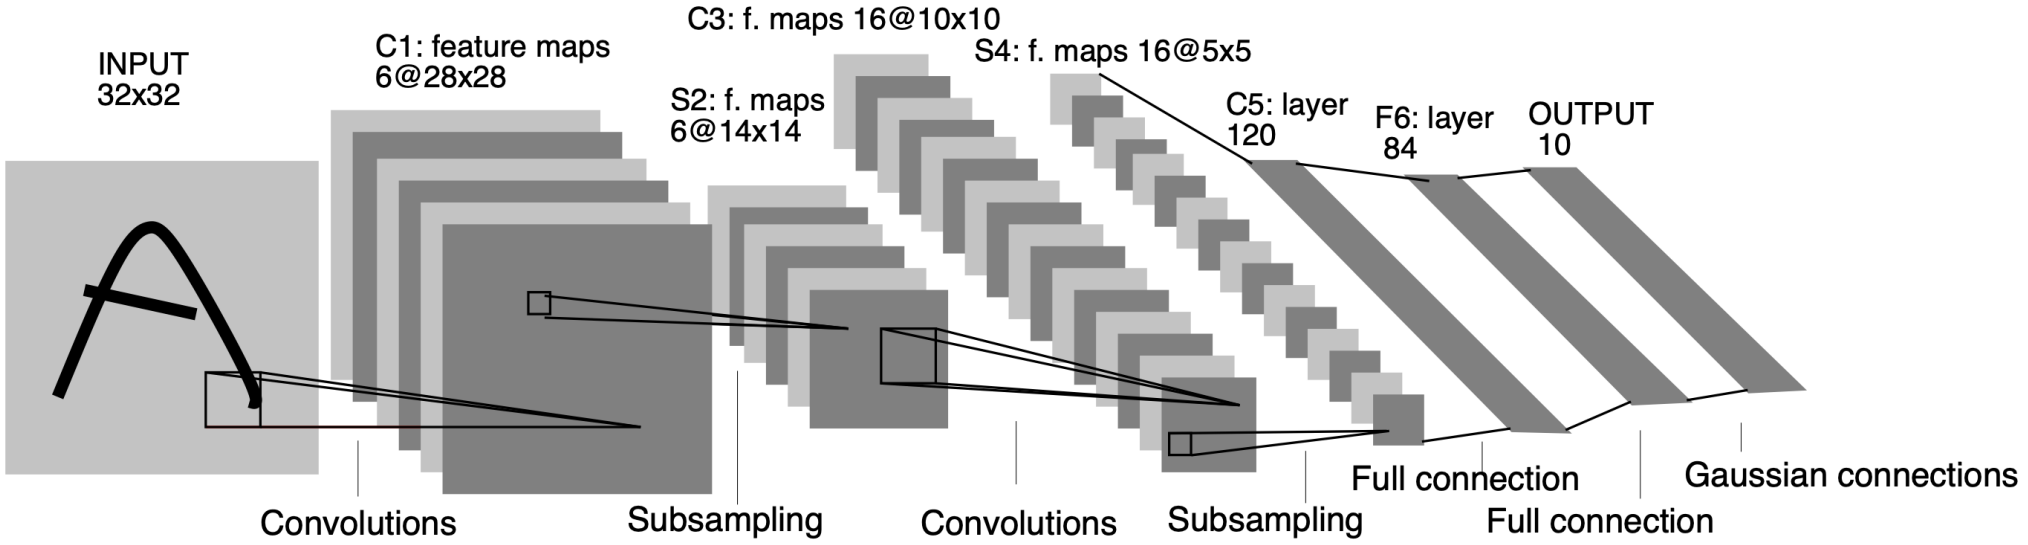

http://yann.lecun.com/exdb/publis/pdf/lecun-98.pdf

AlexNet

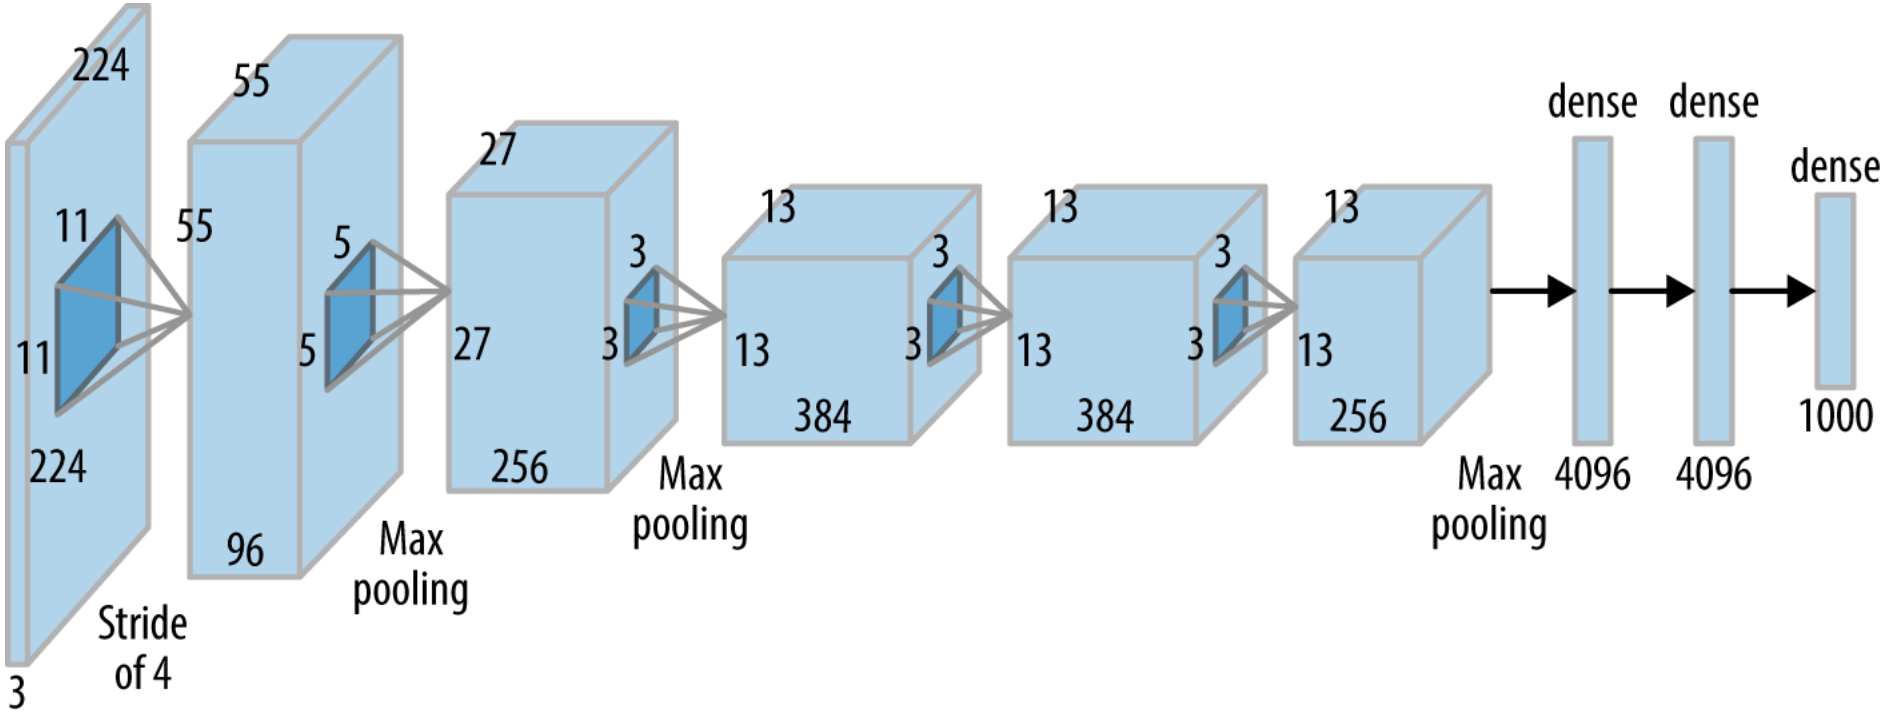

http://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf

Представления с последних слоёв

- Важное наблюдение: выходы полносвязных слоёв являются хорошими признаковыми описаниями изображений
- Полезны во многих задачах
- Например, поиск похожих изображений

Представления с последних слоёв

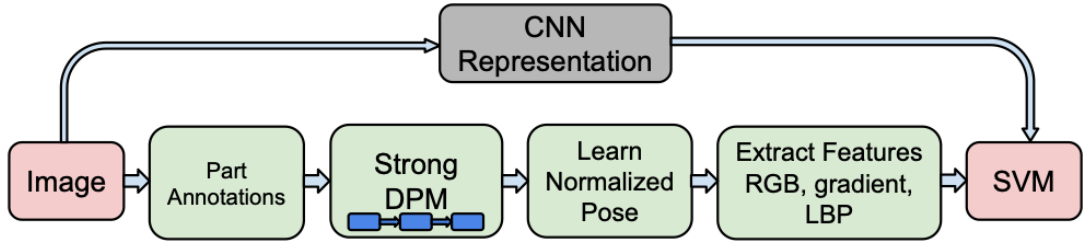

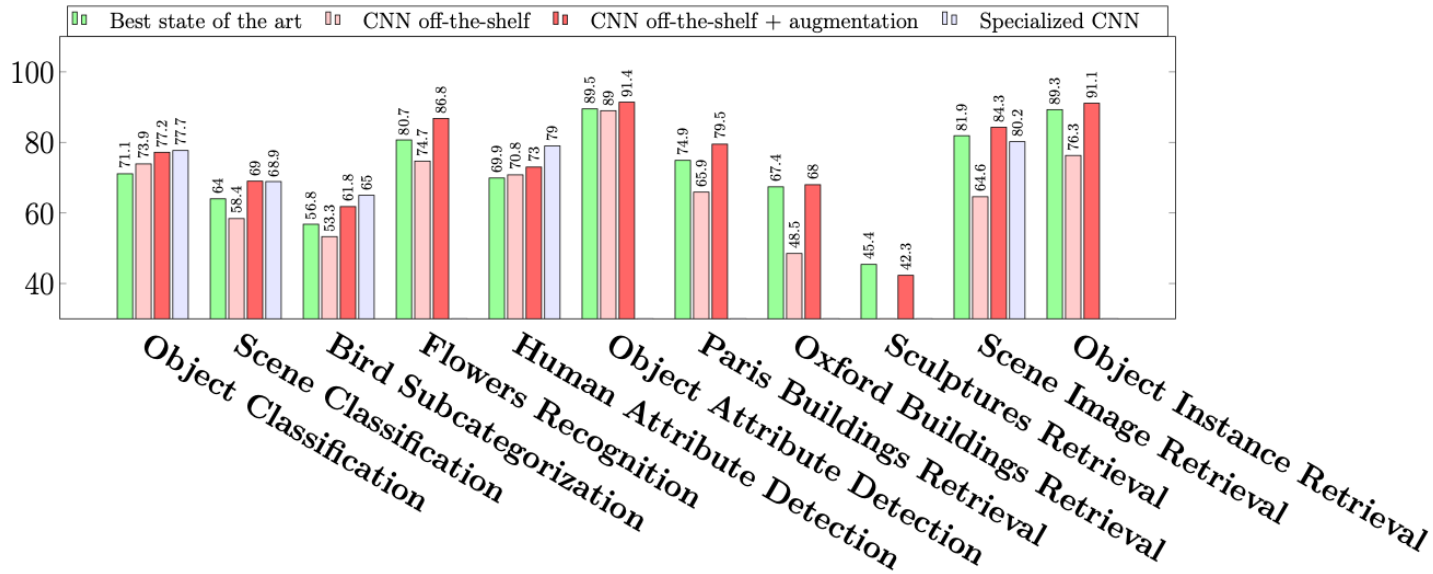

https://arxiv.org/abs/1403.6382

Представления с последних слоёв

- Не интерпретируется (в отличие от классического компьютерного зрения)
- По смыслу — «индикаторы» наличия каких-то паттернов

Представления с последних слоёв

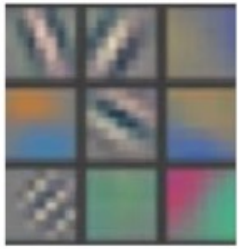

Layer 1

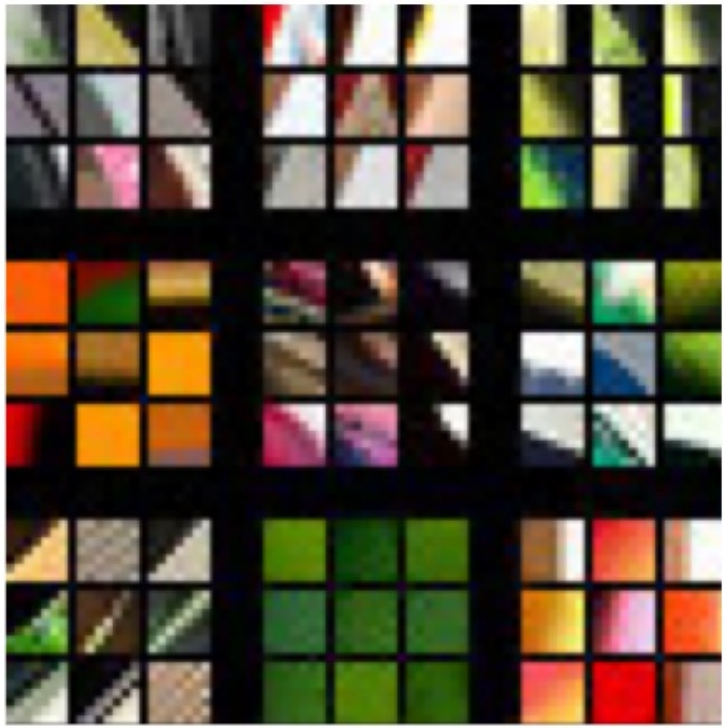

https://arxiv.org/abs/1311.2901

Представления с последних слоёв

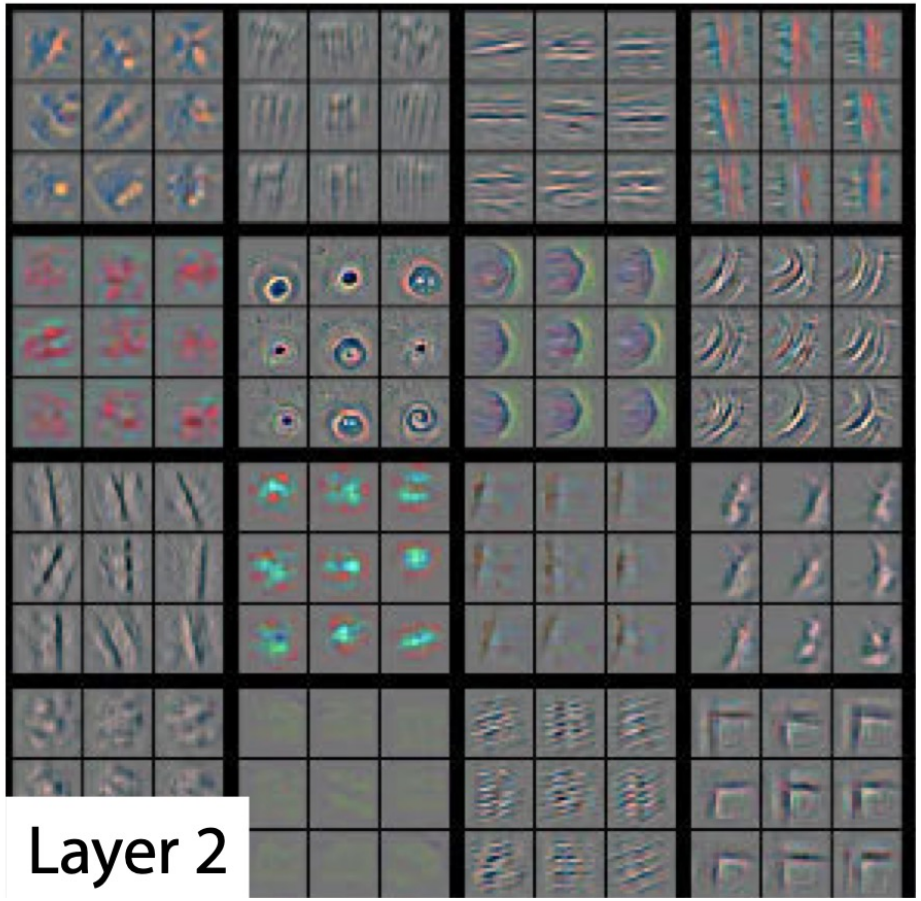

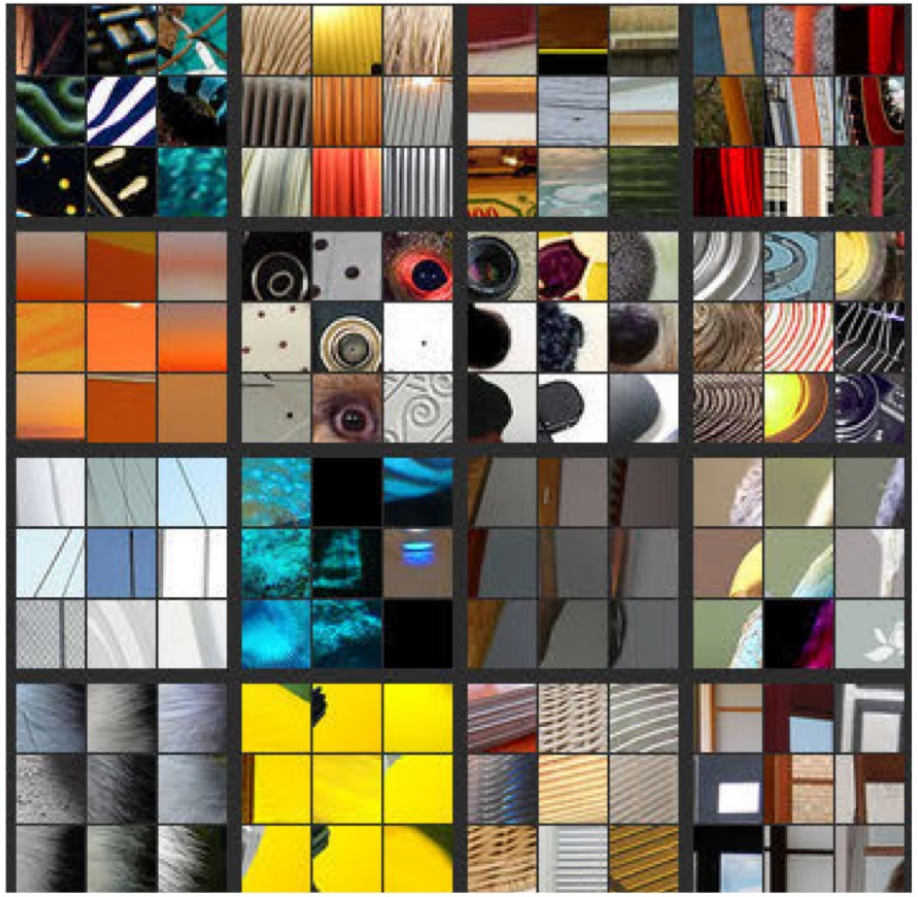

https://arxiv.org/abs/1311.2901

Представления с последних слоёв

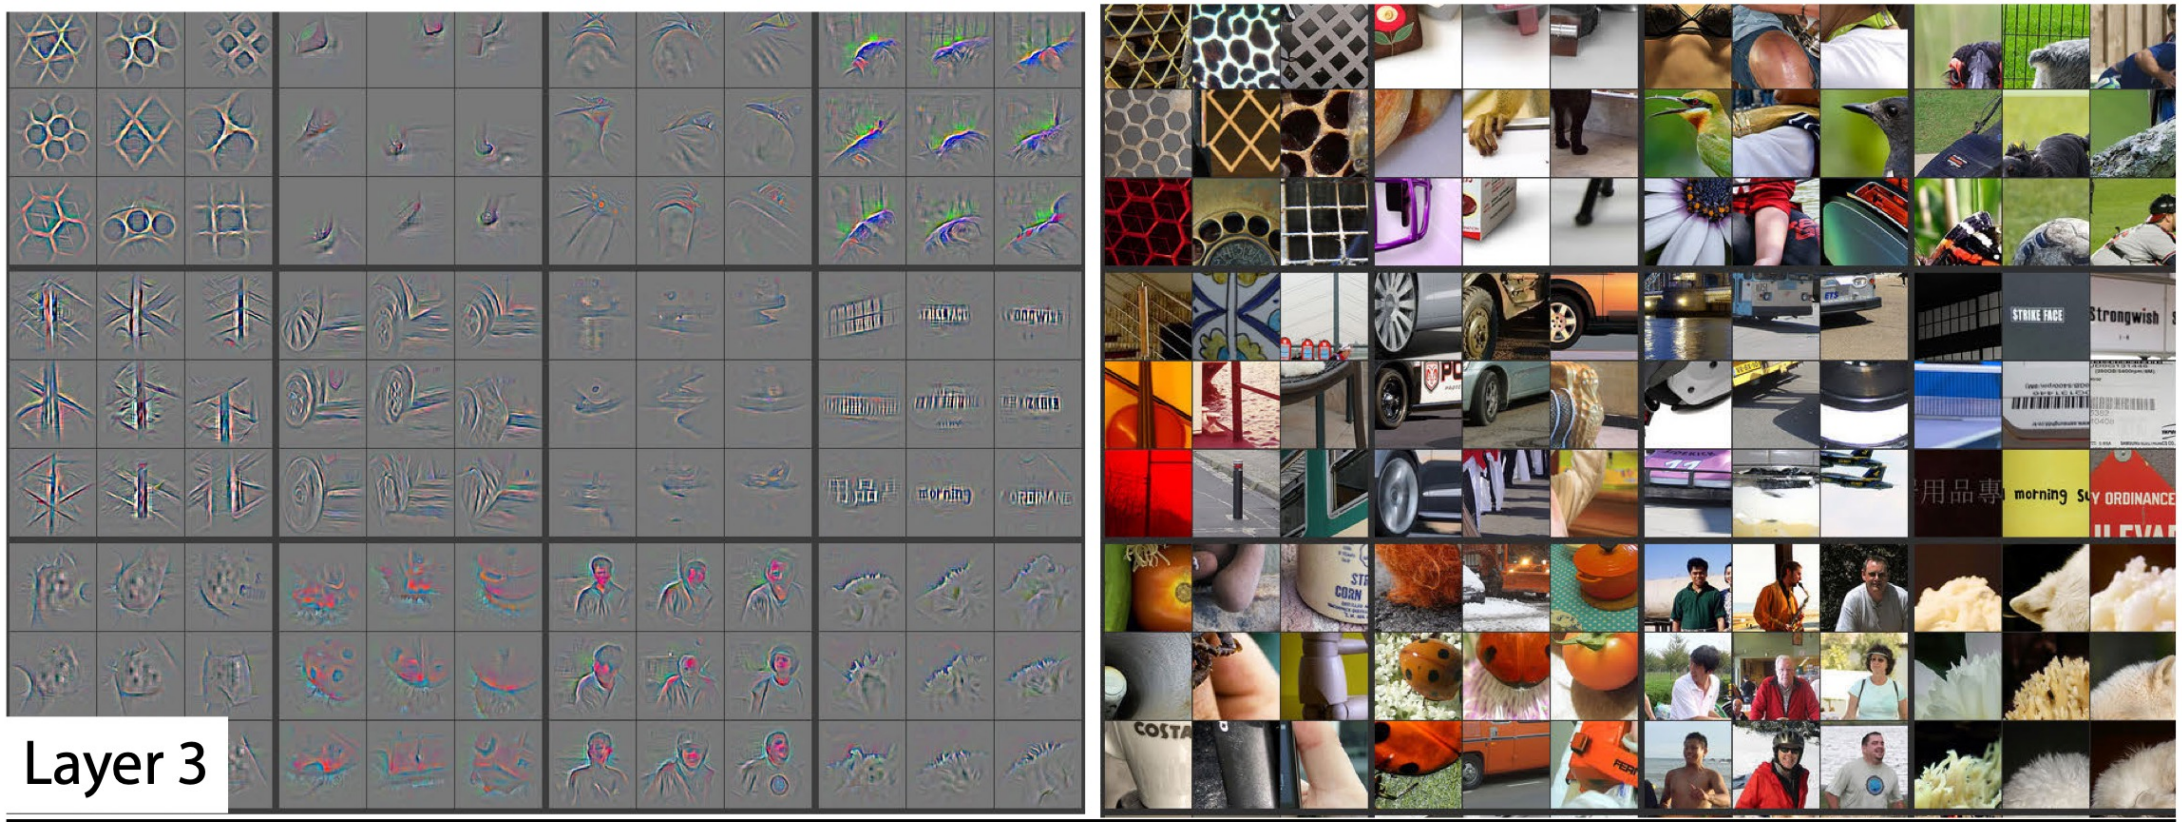

https://arxiv.org/abs/1311.2901

Представления с последних слоёв

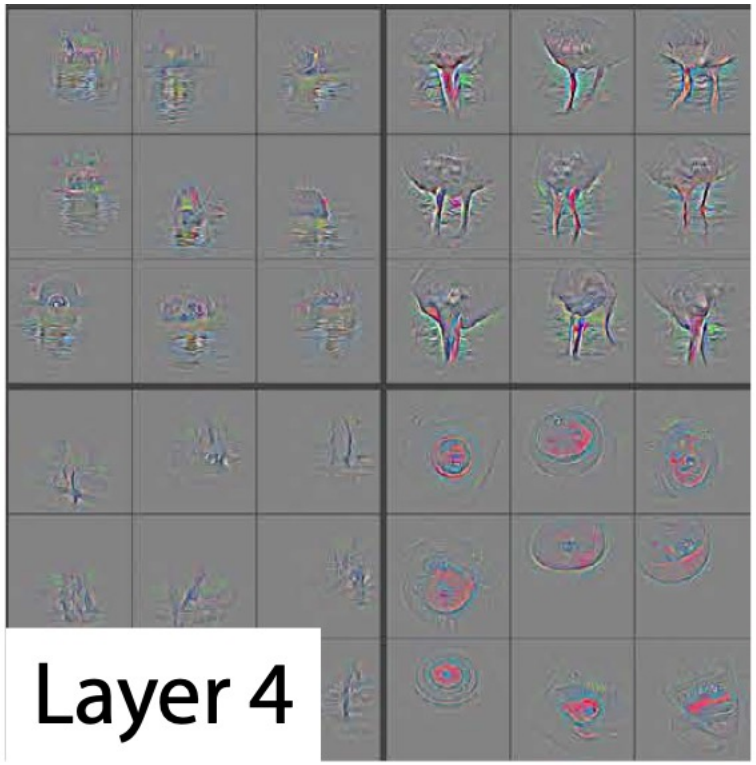

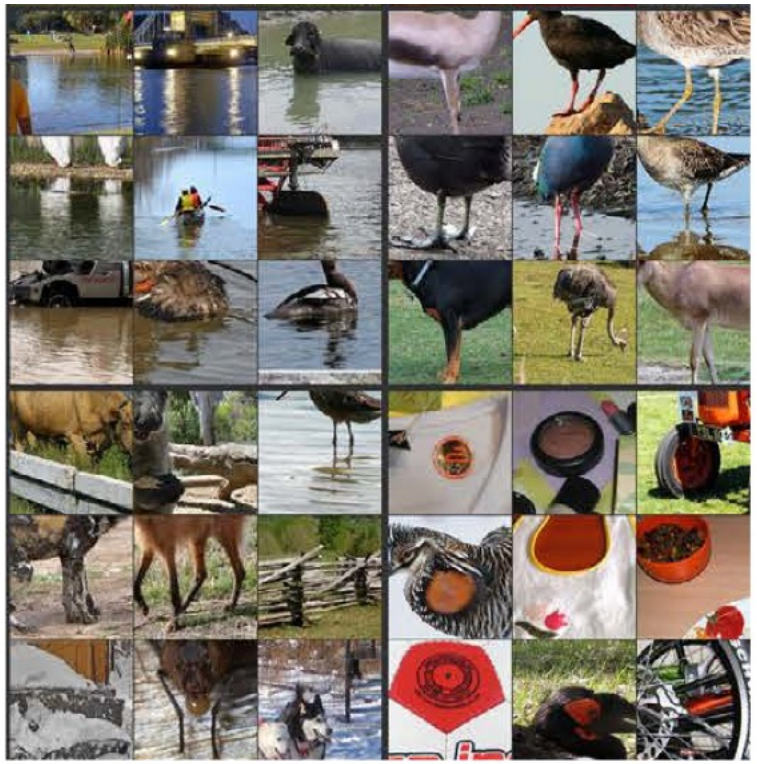

https://arxiv.org/abs/1311.2901

Представления с последних слоёв

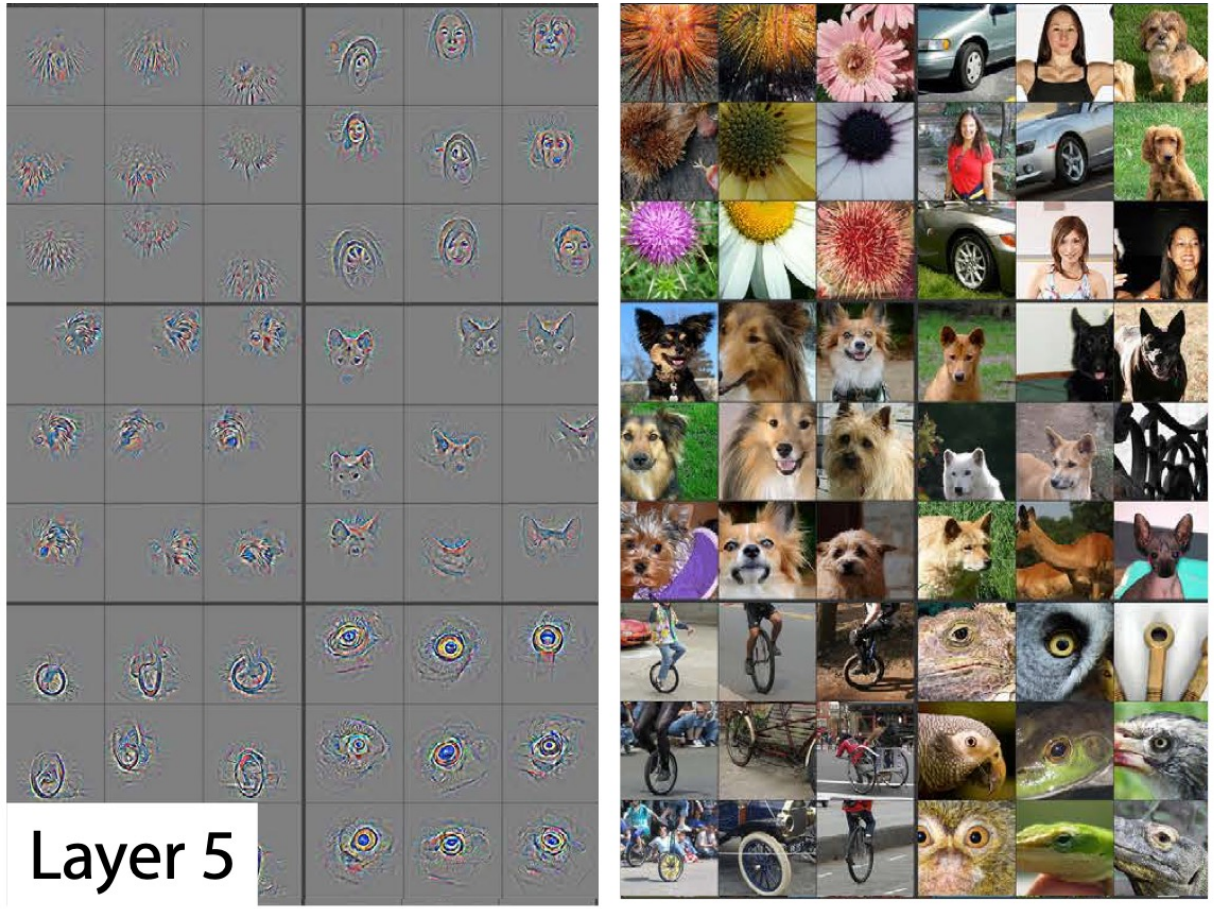

https://arxiv.org/abs/1311.2901